

TRƯỜNG ĐẠI HỌC PHENIKAA



ỨNG DỤNG TRÍ TUỆ NHÂN TẠO TRONG DỰ BÁO THỜI TIẾT

Course/Học phần: Nhập Môn Trí Tuệ Nhân Tạo

Code/Mã học phần: CSE703041

Class/Lớp : N01

Instructor/Giảng viên: Th.S Trần Đình Tân

Group/Nhóm : 8

HÀ NỘI – 2025

DANH SÁCH THÀNH VIÊN TRONG NHÓM

TT	Họ và tên	Lớp -khóa- ngành	Email	Điện thoại	Mã sinh viên	Mức độ đóng góp (theo thang điểm 10)
1	Trương Văn Diệu	K17_KHMT_1	23017208@st.phenikaa- uni.edu.vn	0983078205	23017208	10

MỤC LỤC

<i>I. Giới thiệu</i>	4
1.1. Bối cảnh và động lực.....	4
1.2. Mục tiêu đề tài.....	4
1.3. Đóng góp chính.....	5
<i>II. Phát biểu bài toán</i>	5
2.1. Mô tả bài toán.....	5
2.2. Mô hình toán học.....	6
2.3. Thách thức.....	7
<i>III. Nghiên cứu liên quan</i>	7
3.1. Phương pháp truyền thống.....	7
3.2. Phương pháp hiện đại.....	8
3.3. Phân tích điểm mạnh / hạn chế và khoảng trống nghiên cứu.....	9
<i>IV. Phương pháp đề xuất</i>	10
4.1. Ý tưởng tổng quát.....	10
4.2. Thuật toán chi tiết.....	11
4.3. Phân tích độ phức tạp.....	15
4.4. Hình minh họa.....	16
<i>V. Kết quả thực nghiệm</i>	17
5.1. Cấu hình thực nghiệm.....	17
5.2. Baseline so sánh.....	18
5.3. Dữ liệu sử dụng.....	18
5.4. Tiêu chí đánh giá.....	19
5.5. Phân tích kết quả.....	21
<i>VI. Kết luận</i>	37
<i>VII. Tài liệu Tham khảo</i>	39
<i>VIII. Lời cảm ơn</i>	40

I. Giới thiệu

1.1. Bối cảnh và động lực

Dự báo thời tiết là một lĩnh vực quan trọng, ảnh hưởng trực tiếp đến nhiều khía cạnh của đời sống xã hội và kinh tế. Từ việc lập kế hoạch nông nghiệp, điều phối giao thông, quản lý tài nguyên nước, đến việc ra quyết định trong các hoạt động hàng không, hàng hải và du lịch, thông tin dự báo thời tiết chính xác đóng vai trò then chốt. Đặc biệt, trong bối cảnh biến đổi khí hậu toàn cầu, các hiện tượng thời tiết cực đoan như bão lũ, hạn hán, nắng nóng kỷ lục diễn ra ngày càng thường xuyên và khó lường, gây ra những thiệt hại nặng nề về người và tài sản. Do đó, nhu cầu về một hệ thống dự báo thời tiết không chỉ chính xác mà còn có khả năng thích ứng với sự phức tạp của các yếu tố khí tượng là vô cùng cấp thiết.

Các phương pháp dự báo thời tiết truyền thống thường dựa trên mô hình vật lý phức tạp hoặc kinh nghiệm của chuyên gia, đôi khi gặp khó khăn trong việc xử lý lượng lớn dữ liệu phi tuyến tính và biến động. Sự phát triển vượt bậc của Trí tuệ nhân tạo (Artificial Intelligence – AI), đặc biệt là các thuật toán Học máy (Machine Learning – ML), đã mở ra một hướng tiếp cận mới, mang lại tiềm năng đáng kể trong việc cải thiện độ chính xác và hiệu quả của công tác dự báo. Các thuật toán này có khả năng tự động học hỏi từ dữ liệu lịch sử, phát hiện các mối quan hệ phức tạp và phi tuyến tính giữa các yếu tố khí tượng, từ đó đưa ra dự đoán về các thông số thời tiết trong tương lai. Điều này giúp giảm thiểu sự phụ thuộc vào các giả định mô hình vật lý cứng nhắc và khai thác tối đa giá trị từ dữ liệu lớn, đồng thời minh họa rõ vai trò của AI trong các ứng dụng thực tiễn.

1.2. Mục tiêu đề tài

Đề tài này nhằm mục tiêu xây dựng và đánh giá các mô hình Học máy – một ứng dụng của Trí tuệ nhân tạo (AI) để dự báo thời tiết. Cụ thể, các mục tiêu chính bao gồm:

Xây dựng quy trình tiền xử lý dữ liệu: Phát triển các bước thu thập, làm sạch và chuẩn hóa dữ liệu thời tiết lịch sử (đặc biệt là nhiệt độ và các yếu tố liên quan) nhằm chuẩn bị cho việc huấn luyện các mô hình AI/ML.

Nghiên cứu và áp dụng các thuật toán AI/ML: Khám phá và triển khai các thuật toán học máy phổ biến, phù hợp cho bài toán hồi quy (dự báo nhiệt độ), bao gồm Linear Regression, Support Vector Regressor (SVR), Random Forest Regressor và Gradient Boosting Regressor.

Tối ưu hóa và đánh giá hiệu suất mô hình: Thực hiện tối ưu hóa siêu tham số (hyperparameter tuning) cho các mô hình đã chọn bằng kỹ thuật GridSearchCV và KFold Cross-Validation. Đánh giá toàn diện hiệu suất của các mô hình thông qua các chỉ số như Mean Absolute Error (MAE), Mean Squared Error (MSE), Root Mean Squared Error (RMSE) và R^2 Score để xác định mô hình có khả năng dự báo tốt nhất.

Phân tích và so sánh kết quả: Đánh giá ưu nhược điểm của từng mô hình, so sánh hiệu suất giữa các mô hình trước và sau khi tối ưu hóa, từ đó rút ra nhận xét về hiệu quả của Trí tuệ nhân tạo trong bài toán dự báo thời tiết.

1.3. Đóng góp chính

Đề tài mang lại những đóng góp chính sau:

Xây dựng một quy trình dự báo thời tiết hoàn chỉnh bằng AI/Học máy: Cung cấp một khung làm việc từ tiền xử lý dữ liệu đến huấn luyện, tối ưu hóa và đánh giá mô hình, có thể áp dụng cho các bài toán dự báo thời tiết tương tự.

Đánh giá thực nghiệm hiệu quả của các thuật toán hồi quy: So sánh chi tiết hiệu suất của một số thuật toán hồi quy phổ biến trong ngữ cảnh dự báo nhiệt độ, cung cấp cái nhìn định lượng về khả năng dự đoán của chúng.

Cung cấp mã nguồn thực thi: Mã nguồn được phát triển có thể dùng làm tài liệu tham khảo hoặc cơ sở để phát triển các hệ thống dự báo phức tạp hơn trong tương lai.

Minh họa tiềm năng của tối ưu hóa siêu tham số: Chứng minh vai trò quan trọng của việc điều chỉnh siêu tham số trong việc cải thiện đáng kể hiệu suất của các mô hình AI/Học máy.

II. Phát biểu bài toán

2.1. Mô tả bài toán

Bài toán trọng tâm của đề tài này là dự báo thời tiết dựa trên các yếu tố khí tượng lịch sử. Đây là một bài toán hồi quy (regression problem) trong lĩnh vực Học máy – một ứng dụng của Trí tuệ nhân tạo (AI), nơi mục tiêu là dự đoán một giá trị liên tục (nhiệt độ) thay vì phân loại dữ liệu vào các nhóm rời rạc.

Cụ thể, từ tập dữ liệu `kanpur.csv` chứa các thông tin về thời tiết như nhiệt độ, độ ẩm, tốc độ gió, áp suất, lượng mưa và các yếu tố khác tại các thời điểm khác nhau, chúng ta sẽ xây dựng các mô hình AI/ML để học hỏi mối quan hệ giữa các yếu tố đầu vào này và nhiệt độ tương ứng. Sau khi mô hình được huấn luyện, nó có khả năng nhận các giá trị của các yếu tố đầu vào tại một thời điểm mới và dự đoán giá trị nhiệt độ tại thời điểm đó.

Ví dụ minh họa: Giả sử chúng ta có dữ liệu lịch sử về nhiệt độ, độ ẩm và tốc độ gió của một địa điểm trong nhiều ngày:

Ngày 1: Độ ẩm 70%, Tốc độ gió 10 km/h, Nhiệt độ 25°C

Ngày 2: Độ ẩm 65%, Tốc độ gió 12 km/h, Nhiệt độ 27°C

...

Ngày N: Độ ẩm 72%, Tốc độ gió 8 km/h, Nhiệt độ X°C (cần dự đoán)

Bài toán là tìm một hàm số f sao cho:

$$\text{Nhiệt độ} = f(\text{Độ ẩm, Tốc độ gió, ...})$$

có thể dự đoán chính xác nhiệt độ $X^{\circ}\text{C}$ khi biết các thông số đầu vào.

2.2. Mô hình toán học

Giả sử chúng ta có một tập dữ liệu lịch sử:

$$D = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$$

Trong đó:

N là tổng số bản ghi (quan sát) trong tập dữ liệu.

x_i là véc-tơ các đặc trưng (features) đầu vào cho bản ghi thứ i . Trong bài toán này, x_i có thể bao gồm các yếu tố khí tượng như độ ẩm, tốc độ gió, áp suất, lượng mưa, v.v., tại thời điểm i .

y_i là giá trị nhiệt độ thực tế (target variable) của bản ghi thứ i .

Mục tiêu của bài toán là tìm một hàm ánh xạ $f: X \rightarrow Y$ từ không gian đặc trưng X (không gian của các véc-tơ đầu vào) đến không gian giá trị nhiệt độ Y (tập hợp các số thực), sao cho giá trị dự đoán $y^{\wedge}_i = f(x_i)$ càng gần với giá trị thực tế y_i càng tốt.

Mô hình AI/Học máy sẽ cố gắng học các tham số của hàm f bằng cách tối thiểu hóa một hàm mất mát (loss function) $L(y^{\wedge}_i, y_i)$ trên tập dữ liệu huấn luyện. Các hàm mất mát phổ biến cho bài toán hồi quy bao gồm:

$$\text{Mean Absolute Error (MAE): } L(y, y^{\wedge}) = |y - y^{\wedge}|$$

$$\text{Mean Squared Error (MSE): } L(y, y^{\wedge}) = (y - y^{\wedge})^2$$

Khi mô hình f đã được huấn luyện, với một véc-tơ đặc trưng mới x_{new} (chẳng hạn, độ ẩm, tốc độ gió, v.v., tại một thời điểm trong tương lai mà chúng ta muốn dự đoán nhiệt độ), mô hình sẽ trả về giá trị nhiệt độ dự đoán:

$$y^{\wedge}_{\text{new}} = f(x_{\text{new}})$$

Ghi chú: Hàm mất mát đóng vai trò quan trọng trong quá trình học của mô hình AI, giúp mô hình điều chỉnh các tham số để cải thiện độ chính xác dự đoán.

2.3. Thách thức

Bài toán dự báo thời tiết bằng AI/Học máy đối mặt với một số thách thức đáng kể:

Tính phi tuyến tính và phức tạp của dữ liệu: Mối quan hệ giữa nhiệt độ và các yếu tố khí tượng khác thường không tuyến tính và rất phức tạp, chịu ảnh hưởng bởi nhiều biến số tương tác lẫn nhau. Điều này đòi hỏi các mô hình AI/Học máy có khả năng nắm bắt được các mối quan hệ phi tuyến tính này.

Tính thời gian của dữ liệu: Dữ liệu thời tiết thường là chuỗi thời gian, có tính phụ thuộc vào thời gian (autocorrelation) và tính mùa vụ (seasonality). Việc bỏ qua khía cạnh này có thể dẫn đến dự đoán kém chính xác. Mặc dù dữ liệu hiện tại trong `kanpur.csv` không có cột thời gian rõ ràng để khai thác triệt để tính chất chuỗi thời gian, nhưng đây là một yếu tố cần xem xét trong các bài toán dự báo thời tiết nói chung.

Dữ liệu thiếu và nhiễu: Dữ liệu thời tiết thu thập từ các cảm biến có thể chứa các giá trị thiếu (missing values) hoặc nhiễu (noise) do lỗi đo lường hoặc đường truyền. Việc xử lý hiệu quả các vấn đề này là cần thiết để đảm bảo chất lượng dữ liệu đầu vào cho các mô hình AI.

Lựa chọn mô hình và tối ưu hóa siêu tham số: Có nhiều thuật toán AI/Học máy khác nhau có thể áp dụng cho bài toán hồi quy. Việc lựa chọn mô hình phù hợp nhất và tinh chỉnh các siêu tham số của chúng (hyperparameter tuning) là một thách thức, đòi hỏi kiến thức chuyên sâu và thử nghiệm kỹ lưỡng để đạt được hiệu suất tối ưu.

Đánh giá và giải thích mô hình: Việc đánh giá hiệu suất của mô hình đòi hỏi các chỉ số phù hợp. Hơn nữa, việc giải thích tại sao một mô hình đưa ra dự đoán như vậy (interpretability) cũng là một thách thức, đặc biệt với các mô hình phức tạp như Random Forest hay Gradient Boosting.

III. Nghiên cứu liên quan

Phần này trình bày tổng quan về các phương pháp dự báo thời tiết, từ truyền thống đến hiện đại, đặc biệt tập trung vào ứng dụng của AI/Học máy. Việc phân tích các nghiên cứu đã có giúp định vị vị trí và làm nổi bật đóng góp của đề tài.

3.1. Phương pháp truyền thống

Các phương pháp dự báo thời tiết truyền thống chủ yếu dựa trên vật lý khí quyển và mô hình số.

Dự báo dựa trên khí hậu học (Climatology Forecast): Phương pháp này đơn giản nhất, dự báo thời tiết trong tương lai sẽ giống với giá trị trung bình lịch sử của cùng một ngày hoặc mùa trong quá khứ. Mặc dù dễ thực hiện, phương pháp này bỏ qua các điều kiện thời tiết hiện tại và thường không chính xác cho các sự kiện thời tiết cực đoan.

Dự báo dựa trên sự bền vững (Persistence Forecast): Giả định rằng điều kiện thời tiết trong tương lai gần sẽ giống với điều kiện hiện tại. Phương pháp này có thể hiệu quả trong ngắn hạn (vài giờ) khi thời tiết ít thay đổi, nhưng độ chính xác giảm nhanh chóng theo thời gian.

Mô hình dự báo thời tiết số (Numerical Weather Prediction – NWP): Đây là phương pháp phổ biến và mạnh mẽ nhất trong dự báo thời tiết truyền thống. NWP sử dụng các phương trình toán học phức tạp dựa trên định luật vật lý (như phương trình Navier-Stokes, định luật bảo toàn năng lượng, khối lượng) để mô phỏng sự chuyển động của khí quyển và đại dương. Các mô hình này yêu cầu siêu máy tính để xử lý lượng lớn dữ liệu đầu vào (từ vệ tinh, radar, trạm khí tượng) và tính toán sự phát triển của thời tiết trong tương lai. NWP là xương sống của các trung tâm dự báo thời tiết quốc gia và quốc tế.

Ưu điểm: Có cơ sở vật lý vững chắc, có thể dự báo nhiều yếu tố thời tiết và các hiện tượng phức tạp.
Hạn chế: Rất tốn kém về tài nguyên tính toán, đòi hỏi hiểu biết sâu sắc về vật lý khí quyển, và độ chính xác có thể bị ảnh hưởng bởi điều kiện ban đầu không hoàn hảo (butterfly effect) và sự đơn giản hóa trong mô hình hóa.

Nhìn chung, các phương pháp truyền thống mặc dù mạnh về cơ sở vật lý, nhưng đôi khi gặp khó khăn trong việc khai thác dữ liệu lớn và mô hình hóa các quan hệ phi tuyến tính. Đây chính là lý do các thuật toán AI/Học máy trở thành hướng tiếp cận hiện đại trong dự báo thời tiết.

3.2. Phương pháp hiện đại

Sự phát triển của Trí tuệ nhân tạo (AI), đặc biệt là Học máy (Machine Learning – ML) và Học sâu (Deep Learning – DL), đã mang lại các phương pháp mới cho dự báo thời tiết, đặc biệt trong việc xử lý các mối quan hệ phi tuyến tính và khai thác dữ liệu lớn.

Hồi quy tuyến tính (Linear Regression): Mặc dù là một trong những thuật toán ML đơn giản nhất, Linear Regression vẫn được sử dụng làm baseline trong nhiều nghiên cứu dự báo thời tiết để dự đoán các giá trị liên tục như nhiệt độ, áp suất hoặc tốc độ gió. Mô hình giả định mối quan hệ tuyến tính giữa các biến đầu vào và biến mục tiêu.

Ví dụ tham khảo: D. K. Das và H. L. Devi, "Prediction of Weather Parameters Using Linear Regression Model," International Journal of Engineering Science and Computing (IJESC), Vol. 7, No. 6, 2017.

Hồi quy Véc-tơ Hỗ trợ (Support Vector Regression – SVR): SVR là một phần mở rộng của SVM cho bài toán hồi quy. Nó có khả năng xử lý các mối quan hệ phi tuyến tính thông qua việc sử dụng hàm nhân (kernel functions) và tìm một siêu phẳng tối ưu để mô hình hóa dữ liệu, đồng thời giữ sai số dự đoán trong biên độ cho phép.

Ví dụ tham khảo: S. S. Prasad và S. R. Devi, "Prediction of Weather Parameters Using SVM Regression," IJARCSSE, Vol. 4, No. 3, 2014.

Rừng ngẫu nhiên (Random Forest): Thuật toán học kết hợp (ensemble learning) dựa trên nhiều cây quyết định. Kết quả dự đoán cuối cùng là giá trị trung bình từ các dự đoán của từng cây. Random Forest xử lý tốt các quan hệ phi tuyến tính, ít bị quá khớp (overfitting) và mạnh mẽ với dữ liệu nhiễu.

Ví dụ tham khảo: A. R. S. Bhadoria và G. S. Prasad, "Weather Forecasting using Random Forest Regression," IJCA, Vol. 165, No. 1, 2017.

Gradient Boosting (Gradient Boosting Regressor – GBR): Là kỹ thuật học kết hợp tuần tự, mỗi cây mới cố gắng sửa lỗi từ cây trước đó, tối ưu hóa hàm mất mát theo gradient âm. GBR thường đạt hiệu suất cao trong nhiều bài toán hồi quy.

Ví dụ tham khảo: J. H. Friedman, "Stochastic Gradient Boosting," Computational Statistics & Data Analysis, Vol. 38, No. 4, 2002.

Mạng nơ-ron sâu (Deep Learning – DL): Các kiến trúc như RNN, LSTM và Transformer cho thấy tiềm năng lớn trong dự báo chuỗi thời gian khí tượng nhờ khả năng học các phụ thuộc dài hạn và phức tạp trong dữ liệu.

Ví dụ tham khảo: Z. Zheng et al., "Deep Learning for Meteorological Data Analysis and Weather Forecasting," in Data Science for Resilient Societies, pp. 119-140, Springer, 2020.

Nhìn chung, các phương pháp hiện đại dựa trên AI/Học máy cho phép mô hình hóa các mối quan hệ phi tuyến tính và khai thác tối đa dữ liệu lớn, bổ sung cho các phương pháp truyền thống dựa trên vật lý và mô hình số.

3.3. Phân tích điểm mạnh / hạn chế và khoảng trống nghiên cứu

Tiêu chí	Phương pháp truyền thống (NWP)	Phương pháp hiện đại (AI/Học máy)
Điểm mạnh	- Dựa trên cơ sở vật lý vững chắc. - Có khả năng dự báo các hiện tượng vật lý khí quyển. - Cung cấp cái nhìn vật lý về các quá trình.	- Khả năng xử lý mối quan hệ phi tuyến tính phức tạp. - Hiệu quả với dữ liệu lớn và đa dạng. - Tự động học hỏi mẫu từ dữ liệu, giảm sự phụ thuộc vào giả định. - Linh hoạt, có thể áp dụng cho nhiều loại dữ liệu và mục tiêu dự báo.
Hạn chế	- Yêu cầu tài nguyên tính toán khổng lồ. - Độ chính xác bị ảnh hưởng bởi điều kiện ban đầu và giả định mô hình. - Khó khăn trong việc mô hình hóa các quá trình nhỏ hoặc hỗn loạn. - Kém hiệu quả khi dữ liệu đầu vào nhiều hoặc thiếu.	- Đòi hỏi lượng lớn dữ liệu lịch sử chất lượng cao. - Khó giải thích (black-box) đối với các mô hình phức tạp. - Hiệu suất phụ thuộc nhiều vào việc lựa chọn thuật toán và tối ưu hóa siêu tham số. - Dễ bị quá khớp (overfitting) nếu không kiểm soát tốt.

Khoảng trống nghiên cứu:

Mặc dù các phương pháp AI/Học máy đã đạt được nhiều thành công, vẫn tồn tại một số thách thức:

Kết hợp giữa mô hình vật lý và học máy (Physics-informed ML): Tích hợp các định luật vật lý vào mô hình ML có thể cải thiện khả năng tổng quát hóa và độ tin cậy của dự báo, đặc biệt với các hiện tượng thời tiết hiếm gặp.

Khả năng giải thích (Explainable AI – XAI): Cần phát triển các phương pháp giúp hiểu rõ lý do tại sao mô hình học máy đưa ra dự đoán cụ thể, quan trọng với các ứng dụng nhạy cảm như dự báo thời tiết.

Dự báo cực đoan và không chắc chắn: Cần cải thiện khả năng dự báo các sự kiện thời tiết cực đoan và cung cấp ước lượng về độ không chắc chắn của dự báo.

Tối ưu hóa tài nguyên: Với các mô hình DL lớn, việc tối ưu hóa hiệu quả tính toán và năng lượng vẫn là thách thức.

Đề tài này tập trung vào việc áp dụng và so sánh các mô hình học máy cơ bản (Linear Regression, SVR, Random Forest, GBR) trên một bộ dữ liệu cụ thể để dự báo thời tiết. Mặc dù không đi sâu vào các mô hình DL phức tạp hay tích hợp vật lý, nghiên cứu này minh họa hiệu quả của các thuật toán AI/Học máy cơ bản trong một bài toán thực tế, đồng thời làm nền tảng cho các nghiên cứu chuyên sâu hơn trong tương lai.

IV. Phương pháp đề xuất

Phần này trình bày chi tiết phương pháp được đề xuất để xây dựng mô hình dự báo thời tiết, cụ thể là dự báo nhiệt độ, sử dụng các kỹ thuật AI/Học máy. Quy trình này bao gồm các bước từ chuẩn bị dữ liệu đến lựa chọn, huấn luyện và tối ưu hóa mô hình.

4.1. Ý tưởng tổng quát

Phương pháp đề xuất khai thác sức mạnh của AI/Học máy để học các mối quan hệ phức tạp và phi tuyến tính từ dữ liệu thời tiết lịch sử, thay vì dựa vào các mô hình vật lý phức tạp. Mục tiêu là xây dựng một mô hình dự báo nhiệt độ chính xác dựa trên dữ liệu. Quy trình tổng quát bao gồm các bước sau:

Thu thập dữ liệu: Sử dụng tập dữ liệu lịch sử chứa các thông số khí tượng như nhiệt độ, độ ẩm, áp suất, tốc độ gió, v.v.

Tiền xử lý dữ liệu: Chuẩn bị dữ liệu thô để phù hợp với yêu cầu của các thuật toán AI/Học máy. Bao gồm xử lý giá trị thiếu, mã hóa các biến phân loại (nếu có), và chuẩn hóa hoặc mở rộng dữ liệu số.

Chia tách dữ liệu: Phân chia dữ liệu đã qua tiền xử lý thành tập huấn luyện và tập kiểm tra để đánh giá hiệu suất mô hình một cách khách quan.

Lựa chọn và huấn luyện mô hình: Áp dụng và huấn luyện một số thuật toán hồi quy để tìm mô hình phù hợp nhất cho bài toán dự báo nhiệt độ. Các mô hình được xem xét gồm Linear Regression, Support Vector Regressor (SVR), Random Forest Regressor và Gradient Boosting Regressor (GBR).

Tối ưu hóa siêu tham số: Sử dụng GridSearchCV kết hợp KFold Cross-Validation để tìm bộ siêu tham số tối ưu, nâng cao hiệu suất dự báo.

Đánh giá mô hình: Sử dụng các chỉ số như MAE, MSE, RMSE, R2 Score để đo lường độ chính xác và hiệu quả của mô hình trên tập kiểm tra.

Phân tích kết quả: So sánh hiệu suất giữa các mô hình và rút ra nhận xét về mô hình tối ưu nhất cho bài toán dự báo nhiệt độ.

Quy trình này minh họa cách AI/Học máy có thể được triển khai trong dự báo thời tiết, từ dữ liệu thô đến mô hình dự báo cuối cùng, đồng thời làm cơ sở cho các nghiên cứu và ứng dụng mở rộng trong tương lai.

4.2. Thuật toán chi tiết

Dựa trên ý tưởng tổng quát, các bước chi tiết và thuật toán được sử dụng trong đề tài bao gồm:

a. Chuẩn bị dữ liệu

Tải dữ liệu

Đọc dữ liệu từ file `kanpur.csv` vào `DataFrame` của `Pandas`.

```
df = pd.read_csv("kanpur.csv")
```

Xử lý giá trị thiếu

Các giá trị thiếu được thay thế bằng giá trị trung bình (mean) của từng cột.

```
df.fillna(df.mean(), inplace=True)
```

Xác định biến mục tiêu và đặc trưng

Biến mục tiêu (target variable): `Temperature (C)`

Biến đặc trưng (features): các cột còn lại.

```
X = df.drop("Temperature (C)", axis=1)
```

```
y = df["Temperature (C)"]
```

Chia tách tập dữ liệu

Tách dữ liệu thành tập huấn luyện (80%) và tập kiểm tra (20%).

```
X_train, X_test, y_train, y_test = train_test_split(  
    X, y, test_size=0.2, random_state=42  
)
```

Chuẩn hóa dữ liệu (Feature Scaling)

Sử dụng StandardScaler để chuẩn hóa dữ liệu đầu vào.

```
scaler = preprocessing.StandardScaler()

X_train_scaled = scaler.fit_transform(X_train)

X_test_scaled = scaler.transform(X_test)
```

b. Các mô hình Machine Learning

1. Linear Regression

Mô tả: Mô hình tuyến tính, dự đoán biến mục tiêu bằng tổ hợp tuyến tính của các biến đặc trưng.

Huấn luyện:

```
model_lr = LinearRegression()

model_lr.fit(X_train_scaled, y_train)
```

2. Support Vector Regressor (SVR)

Mô tả: Tìm siêu phẳng (hyperplane) với sai số nhỏ nhất, cho phép một biên độ dung sai (epsilon-tube). Có thể xử lý quan hệ phi tuyến bằng kernel trick.

Tối ưu tham số: `C`, `gamma`, `kernel` thông qua GridSearchCV.

```
param_grid_svr = {"C": [0.1, 1, 10], "gamma": ["scale", "auto"],
                  "kernel": ["rbf"]}

grid_svr = GridSearchCV(
    SVR(),
    param_grid=param_grid_svr,
    cv=KFold(n_splits=5, shuffle=True, random_state=42),
    scoring="neg_mean_squared_error",
    n_jobs=-1
)
```

3. Random Forest Regressor

Mô tả: Thuật toán ensemble dựa trên nhiều cây quyết định ngẫu nhiên. Kết quả là trung bình dự đoán của các cây → giảm phương sai, hạn chế overfitting.

Huấn luyện:

```
model_rf = RandomForestRegressor(random_state=42)
model_rf.fit(X_train_scaled, y_train)
```

4. Gradient Boosting Regressor (GBR)

Mô tả: Xây dựng cây quyết định một cách tuần tự. Mỗi cây mới khắc phục lỗi còn lại của tổ hợp trước đó bằng gradient descent.

Tối ưu tham số: `n_estimators`, `learning_rate`, `max_depth` thông qua `GridSearchCV`.

```
param_grid_gbr = {
    "n_estimators": [100, 200],
    "learning_rate": [0.05, 0.1],
    "max_depth": [3, 5]
}

grid_gbr = GridSearchCV(
    GradientBoostingRegressor(),
    param_grid=param_grid_gbr,
    cv=KFold(n_splits=5, shuffle=True, random_state=42),
    scoring="neg_mean_squared_error",
    n_jobs=-1
)
```

c. Đánh giá mô hình

Các mô hình được đánh giá trên tập kiểm tra bằng các chỉ số:

Mean Absolute Error (MAE)

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

Mean Squared Error (MSE)

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Root Mean Squared Error (RMSE)

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

Hệ số xác định (R^2 Score)

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$$

Trong đó:

y_i : giá trị thực tế

$\hat{y}_i$: giá trị dự đoán

$\bar{y}$: giá trị trung bình của tập dữ liệu

4.3. Phân tích độ phức tạp

Độ phức tạp tính toán của các thuật toán sử dụng trong đề tài có thể ước lượng như sau:

Linear Regression

Huấn luyện:

Nếu dùng phương pháp giải trực tiếp (ma trận nghịch đảo): $O(D^3)$

Nếu dùng giải pháp theo gradient descent: $O(ND^2)$

Trong đó: N là số mẫu, D là số đặc trưng.

Dự đoán: $O(D)$

Support Vector Regressor (SVR)

Huấn luyện: từ $O(N^2D)$ đến $O(N^3)$, phụ thuộc vào số lượng mẫu và phương pháp tối ưu. Với dữ liệu lớn, SVR huấn luyện khá chậm.

Dự đoán: $O(D.S)$, trong đó S là số vector hỗ trợ (support vectors).

Random Forest Regressor

Huấn luyện: $O(K.M.D\log N)$

K : số lượng cây

M : số đặc trưng được chọn ngẫu nhiên tại mỗi nút

D : số đặc trưng

N : số mẫu

Dự đoán: $O(K.D)$

Ưu điểm: có thể song song hóa việc xây dựng cây, giúp tăng tốc độ huấn luyện.

Gradient Boosting Regressor (GBR)

Huấn luyện: $O(K.N.D)$

Do các cây được xây dựng tuần tự, việc song song hóa khó hơn Random Forest.

Dự đoán: $O(K.D)$

Nhận xét

Các mô hình ensemble (Random Forest, Gradient Boosting) thường có độ phức tạp huấn luyện cao hơn so với Linear Regression hoặc SVR.

Tuy nhiên, chúng mang lại hiệu suất dự báo tốt hơn, đặc biệt với dữ liệu có quan hệ phi tuyến.

Khi tối ưu hóa siêu tham số bằng GridSearchCV, việc sử dụng `n_jobs=-1` giúp tận dụng tối đa tài nguyên CPU (đa lõi), từ đó rút ngắn thời gian huấn luyện.

4.4. Hình minh họa

Dưới đây là một sơ đồ lược đồ minh họa quy trình dự báo thời tiết (nhiệt độ) bằng Machine Learning được đề xuất:

```
graph TD
    A[Dữ liệu thô<br>(kanpur.csv)] --> B[Tiền xử lý dữ liệu];
    B -- Xử lý NaN, Chuẩn hóa --> C[Dữ liệu sạch & chuẩn hóa];
    C -- train_test_split --> D1[Tập huấn luyện] & D2[Tập kiểm tra];
    D1 -- Huấn luyện --> E1[Mô hình Linear Regression];
    D1 -- Huấn luyện & GridSearchCV --> E2[Mô hình SVR tối ưu];
    D1 -- Huấn luyện --> E3[Mô hình Random Forest];
    D1 -- Huấn luyện & GridSearchCV --> E4[Mô hình GBR tối ưu];
    E1 -- Dự đoán --> F1[Kết quả dự đoán LR];
    E2 -- Dự đoán --> F2[Kết quả dự đoán SVR];
    E3 -- Dự đoán --> F3[Kết quả dự đoán RF];
    E4 -- Dự đoán --> F4[Kết quả dự đoán GBR];
    F1, F2, F3, F4 --> G[Đánh giá hiệu suất<br>(MAE, MSE, RMSE, R2)];
    G --> H[So sánh & Phân tích kết quả];
    H --> I[Báo cáo cuối cùng];
```


Mô tả Sơ đồ:

Dữ liệu thô: Dữ liệu gốc từ file `kanpur.csv`.

Tiền xử lý dữ liệu: Các bước làm sạch dữ liệu như xử lý giá trị thiếu (fillna), và chuẩn hóa dữ liệu số (StandardScaler).

Dữ liệu sạch & chuẩn hóa: Dữ liệu đã sẵn sàng để đưa vào mô hình.

Chia tập huấn luyện và kiểm tra: Dữ liệu được chia thành hai phần riêng biệt để huấn luyện và đánh giá mô hình độc lập.

Huấn luyện các mô hình: Các mô hình Linear Regression, SVR, Random Forest Regressor, và Gradient Boosting Regressor được huấn luyện trên tập huấn luyện. Đối với SVR và GBR, quá trình huấn luyện bao gồm cả tối ưu hóa siêu tham số bằng GridSearchCV.

Dự đoán: Các mô hình đã huấn luyện sẽ dự đoán nhiệt độ trên tập kiểm tra.

Đánh giá hiệu suất: So sánh các giá trị dự đoán với giá trị thực tế trên tập kiểm tra bằng các metric đã định nghĩa.

So sánh & Phân tích kết quả: Phân tích chi tiết hiệu suất của từng mô hình và rút ra kết luận.

Báo cáo cuối cùng: Tổng hợp toàn bộ quá trình và kết quả.

V. Kết quả thực nghiệm

Phần này trình bày chi tiết các cấu hình thực nghiệm, dữ liệu được sử dụng, tiêu chí đánh giá và phân tích kết quả đạt được từ việc triển khai các mô hình AI/Học máy để dự báo thời tiết (cụ thể là nhiệt độ).

5.1. Cấu hình thực nghiệm

Phần này mô tả môi trường và tham số được sử dụng trong thực nghiệm triển khai các mô hình AI/Học máy để dự báo nhiệt độ.

+ Môi trường phát triển:

Ngôn ngữ lập trình: Python

Thư viện chính: numpy, pandas, scikit-learn, matplotlib

Môi trường thực thi: Google Colab hoặc Jupyter Notebook

Phần cứng: Thực nghiệm sử dụng tài nguyên máy tính sẵn có (Google Colab cung cấp GPU/TPU cho các tác vụ tính toán lớn, mặc dù các mô hình hồi quy chủ yếu chạy trên CPU).

+ Tham số chung:

Tỷ lệ chia dữ liệu: 80% cho huấn luyện, 20% cho kiểm tra (`test_size=0.2`)

Ngẫu nhiên hóa: `random_state=42` được sử dụng trong các hàm chia dữ liệu (`train_test_split`) và khởi tạo mô hình (`RandomForestRegressor`) để đảm bảo tính khả lặp của kết quả

K-Fold Cross-Validation: 5 folds (`n_splits=5`) trong `GridSearchCV` để đánh giá và tối ưu hóa siêu tham số

Tiêu chí đánh giá: `neg_mean_squared_error` (âm của MSE) được sử dụng để tìm mô hình có MSE thấp nhất

Các cấu hình này đảm bảo quá trình huấn luyện và đánh giá mô hình được thực hiện một cách khách quan, khả lặp, đồng thời tạo điều kiện so sánh hiệu suất giữa các thuật toán AI/Học máy khác nhau.

5.2. Baseline so sánh

Để đánh giá hiệu quả các mô hình AI/Học máy, Linear Regression được sử dụng làm mô hình baseline. Linear Regression là một thuật toán hồi quy đơn giản, giả định mối quan hệ tuyến tính giữa các đặc trưng và biến mục tiêu. Hiệu suất của các mô hình phức tạp hơn như SVR, Random Forest, Gradient Boosting sẽ được so sánh với baseline này để xác định mức cải thiện đạt được.

Việc chọn Linear Regression làm baseline là hợp lý bởi:

Cung cấp điểm tham chiếu rõ ràng, dễ hiểu và dễ tính toán.

Giúp xác định xem bài toán có thể được giải quyết tốt bằng mô hình đơn giản hay cần các mô hình phức tạp hơn để nắm bắt các mối quan hệ phi tuyến tính trong dữ liệu.

Mô hình baseline đóng vai trò quan trọng trong việc đánh giá giá trị bổ sung của các thuật toán AI/Học máy phức tạp trong dự báo nhiệt độ.

5.3. Dữ liệu sử dụng

+ Nguồn dữ liệu: Dữ liệu được sử dụng trong đề tài được lấy từ file `kanpur.csv`.

+ Mô tả dữ liệu: File `kanpur.csv` chứa các bản ghi lịch sử về các yếu tố khí tượng. Mặc dù cấu trúc chính xác của file không được hiển thị đầy đủ trong notebook, dựa trên code, có thể suy ra rằng dữ liệu bao gồm các cột là các đặc trưng đầu vào (như độ ẩm, áp suất, tốc độ gió, v.v., mặc dù tên cụ thể không được hiển thị rõ ràng ngoài "Temperature(C)") và một cột là biến mục tiêu:

Biến mục tiêu (Target Variable): `Temperature (C)` (Nhiệt độ theo độ C).

Biến đặc trưng (Features): Các cột khác trong tập dữ liệu, được sử dụng để dự đoán nhiệt độ.

+ Tiền xử lý dữ liệu:

Xử lý giá trị thiếu: Tất cả các giá trị thiếu (NaN) trong tập dữ liệu được điền bằng giá trị trung bình của cột tương ứng. Đây là một phương pháp đơn giản để xử lý dữ liệu thiếu, đảm bảo các mô hình không bị lỗi do thiếu thông tin.

Chuẩn hóa dữ liệu: Các đặc trưng đầu vào được chuẩn hóa bằng `StandardScaler`. Quá trình này biến đổi dữ liệu sao cho chúng có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1. Điều này rất quan trọng đối với các thuật toán như SVR và Linear Regression, giúp chúng hoạt động hiệu quả hơn bằng cách đảm bảo tất cả các đặc trưng có cùng thang đo, tránh việc các đặc trưng có giá trị lớn hơn chi phối quá trình học.

5.4. Tiêu chí đánh giá

Để đánh giá hiệu suất của các mô hình hồi quy, các chỉ số sau được sử dụng:

* Mean Absolute Error (MAE):

Đo lường giá trị trung bình của sai số tuyệt đối giữa dự đoán và giá trị thực tế.

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

MAE có cùng đơn vị với biến mục tiêu, dễ diễn giải. Giá trị càng nhỏ càng tốt.

* Mean Squared Error (MSE):

Trung bình của bình phương sai số. So với MAE, MSE nhạy hơn với các sai số lớn (outliers).

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Giá trị càng nhỏ càng tốt.

* Root Mean Squared Error (RMSE):

Là căn bậc hai của MSE, giúp kết quả có cùng đơn vị với biến mục tiêu.

$$\text{RMSE} = \sqrt{\text{MSE}}$$

RMSE giữ đặc tính phạt sai số lớn của MSE, đồng thời dễ hiểu hơn.

* R² Score (Hệ số xác định):

Biểu thị mức độ mô hình giải thích được phương sai của biến mục tiêu.

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$$

R² gần 1: mô hình giải thích tốt.

R² ≈ 0: mô hình hầu như không giải thích được dữ liệu.

R² < 0: mô hình tệ hơn cả dự đoán bằng giá trị trung bình.

Lý do lựa chọn:

MAE và RMSE phản ánh sai số dự đoán trung bình ở thang đo thực tế.


MSE và RMSE phạt nặng các dự đoán sai lệch lớn, giúp phát hiện mô hình kém ổn định.

R² cho biết khả năng giải thích tổng thể của mô hình.

Việc kết hợp các tiêu chí trên cung cấp một cái nhìn toàn diện, cân bằng giữa sai số trung bình, ảnh hưởng của ngoại lệ, và khả năng giải thích của mô hình.

5.5. Phân tích kết quả

Phân tích kết quả vẽ biểu đồ cho các giá trị của các cột trong dataframe:



Biểu đồ này hiển thị sự biến động của từng đặc trưng số theo chỉ số hàng trong DataFrame. Mặc dù không có cột thời gian rõ ràng để biểu đồ thể hiện xu hướng theo ngày/giờ, nhưng chúng ta vẫn có thể quan sát được sự thay đổi của các giá trị qua các bản ghi.

a. Nhận xét tổng quan về các đặc trưng:

Temperature(C) (Nhiệt độ):

Biểu đồ cho thấy sự biến động đáng kể của nhiệt độ. Có những chu kỳ tăng giảm rõ ràng, gợi ý về tính mùa vụ hoặc chu kỳ ngày/đêm trong dữ liệu.

Phạm vi biến động rộng, từ khoảng 10°C đến hơn 40°C, phản ánh các điều kiện thời tiết đa dạng.

Humidity (Độ ẩm):

Độ ẩm cũng cho thấy sự biến động lớn, với các giá trị dao động từ khoảng 40% đến gần 100%.

Có vẻ như có một mối quan hệ ngược chiều nào đó với nhiệt độ (khi nhiệt độ cao thì độ ẩm có xu hướng thấp hơn, và ngược lại), nhưng cần phân tích tương quan cụ thể để xác nhận.

Wind Speed (km/h) (Tốc độ gió):

Tốc độ gió biến động trong một phạm vi hẹp hơn so với nhiệt độ và độ ẩm, chủ yếu từ 5 đến 15 km/h, đôi khi có những đỉnh cao hơn một chút.

Biểu đồ khá "ổn định" hơn, ít có các dao động lớn đột ngột.

Pressure (millibars) (Áp suất):

Áp suất có vẻ ổn định nhất trong số các đặc trưng, với các giá trị dao động nhẹ quanh mức trung bình.

Biểu đồ gần như là một đường thẳng, chỉ có những thay đổi nhỏ, phù hợp với nhận xét từ describe() về độ lệch chuẩn thấp.

Precipitation (mm) (Lượng mưa):

Biểu đồ này rất khác biệt. Nó cho thấy phần lớn các giá trị là 0, chỉ thỉnh thoảng mới có các "đỉnh" nhỏ biểu thị lượng mưa.

Điều này xác nhận rằng tập dữ liệu chủ yếu ghi nhận các ngày không mưa hoặc mưa rất ít, và lượng mưa nếu có cũng rất nhỏ.

b. Ý nghĩa đối với mô hình dự báo thời tiết:

Đặc trưng biến động mạnh (Nhiệt độ, Độ ẩm): Các đặc trưng này rất quan trọng vì chúng thể hiện sự thay đổi liên tục của thời tiết. Các mô hình học máy sẽ cố gắng tìm ra các mẫu và mối quan hệ từ những biến động này để dự đoán nhiệt độ.

Đặc trưng ổn định (Áp suất): Áp suất có vẻ ít biến động hơn, nhưng nó vẫn là một yếu tố khí tượng quan trọng có thể ảnh hưởng đến nhiệt độ. Mô hình vẫn có thể học được mối quan hệ từ những thay đổi nhỏ này.

Đặc trưng rời rạc/ít xuất hiện (Lượng mưa): Việc lượng mưa chủ yếu bằng 0 có thể là một thách thức đối với mô hình.

Nếu mô hình coi lượng mưa là một biến liên tục, nó có thể gặp khó khăn khi học từ dữ liệu bị lệch mạnh này.


Trong tương lai, có thể cân nhắc chuyển đổi biến này thành biến phân loại (ví dụ: "có mưa" / "không mưa") hoặc sử dụng các kỹ thuật xử lý dữ liệu đặc biệt cho các biến có nhiều giá trị 0. Tuy nhiên, trong phạm vi hiện tại, nó vẫn được sử dụng như một đặc trưng số.

Tính chu kỳ/xu hướng: Sự xuất hiện của các chu kỳ trong nhiệt độ và độ ẩm cho thấy tiềm năng của các mô hình có khả năng nắm bắt được phụ thuộc thời gian (nếu dữ liệu được sắp xếp theo thời gian). Mặc dù các mô hình bạn sử dụng (LR, SVR, RF, GBR) không phải là

mô hình chuỗi thời gian chuyên biệt, nhưng chúng vẫn có thể học được các mối quan hệ dựa trên sự tương quan giữa các đặc trưng tại một thời điểm nhất định.

Nhìn chung, các biểu đồ này cung cấp cái nhìn trực quan về "hành vi" của từng đặc trưng trong tập dữ liệu, củng cố thêm những nhận xét từ describe() và giúp định hướng cho việc hiểu kết quả của các mô hình học máy.

Phân tích kết quả vẽ biểu đồ histogram:



Các biểu đồ histogram này cung cấp cái nhìn sâu sắc về cách các giá trị của mỗi đặc trưng được phân bố trong tập dữ liệu.

a. Phân tích từng đặc trưng:

Temperature(C) (Nhiệt độ):

Biểu đồ cho thấy nhiệt độ có phân phối gần giống hình chuông (bell-shaped distribution) nhưng hơi lệch trái (skewed left), với phần lớn dữ liệu tập trung ở khoảng 20-30°C.

Có một số lượng đáng kể các ngày có nhiệt độ thấp (dưới 20°C) và cao (trên 35°C), thể hiện sự đa dạng về điều kiện nhiệt độ trong tập dữ liệu.

Phân phối này khá tốt cho việc dự đoán vì nó không quá lệch và có đủ sự biến thiên để mô hình học hỏi.

Humidity (Độ ẩm):

Phân phối độ ẩm cho thấy tập trung lớn ở khoảng giá trị cao (từ 70% trở lên), đặc biệt là từ 80-90%.

Có một số lượng nhỏ các ngày có độ ẩm thấp (dưới 60%).

Phân phối này hơi lệch trái, cho thấy phần lớn thời gian độ ẩm tương đối cao.

Wind Speed (km/h) (Tốc độ gió):

Tốc độ gió có phân phối lệch phải (skewed right), với phần lớn các giá trị tập trung ở mức thấp (dưới 10 km/h).

Số lượng các ngày có tốc độ gió cao (trên 15 km/h) là khá ít. Điều này cho thấy gió thường nhẹ trong khu vực dữ liệu này.

Pressure (millibars) (Áp suất):

Áp suất có phân phối khá chuẩn, tập trung rõ rệt quanh giá trị trung bình (khoảng 1015-1020 millibars).

Đây là một phân phối gần như đối xứng, xác nhận rằng áp suất tương đối ổn định và ít biến động.

Precipitation (mm) (Lượng mưa):

Biểu đồ này xác nhận mạnh mẽ nhận định từ describe() và biểu đồ đường: lượng mưa có phân phối cực kỳ lệch phải.

Phần lớn các thanh biểu đồ tập trung ở mức 0, cho thấy đa số các bản ghi là không có mưa.

Chỉ có một số lượng rất nhỏ các bản ghi có giá trị mưa khác 0, và các giá trị này cũng rất nhỏ.

Phân phối này là một thách thức cho các mô hình hồi quy thông thường vì nó không tuân theo phân phối chuẩn và có nhiều giá trị bằng 0.

b. Ý nghĩa đối với bài toán dự báo và tiền xử lý:

Tính chất dữ liệu: Các histogram giúp xác nhận rằng dữ liệu có các phân phối khác nhau, một số gần chuẩn (Pressure), một số lệch (Humidity, Wind Speed), và một số cực kỳ lệch (Precipitation).

Tiền xử lý:

Việc chuẩn hóa dữ liệu bằng StandardScaler (như bạn đã làm) là cần thiết, đặc biệt với các cột có phân phối lệch hoặc phạm vi giá trị lớn, để đưa chúng về cùng một thang đo, giúp các thuật toán học máy hoạt động hiệu quả hơn.

Đối với Precipitation, nếu nó là một đặc trưng quan trọng và mô hình gặp khó khăn, có thể cân nhắc các kỹ thuật biến đổi dữ liệu (ví dụ: biến đổi log, hoặc sử dụng các mô hình robust hơn với outliers) hoặc thậm chí biến nó thành một đặc trưng phân loại (mưa/không mưa). Tuy nhiên, với mục tiêu dự báo nhiệt độ, tác động của Precipitation có thể không lớn bằng các yếu tố khác.

Hiểu biết mô hình: Khi các mô hình học, chúng sẽ cố gắng tìm ra mối quan hệ từ những phân phối này. Ví dụ, một mô hình sẽ học rằng phần lớn các ngày có độ ẩm cao, và điều này có thể liên quan đến một khoảng nhiệt độ nhất định.

Nhìn chung, các biểu đồ histogram này là một bước phân tích khám phá dữ liệu hiệu quả, cung cấp cái nhìn sâu sắc về đặc điểm thống kê của từng biến và gợi ý về các bước tiền xử lý cần thiết.

** Phân tích kết quả của Mô hình Linear Regression:*

```
▼ LinearRegression ⓘ ?  
LinearRegression()  
# Kết quả các chỉ số bị ẩn do nền tảng.
```

Nhận xét:

Độ chính xác tương đối:

MAE (4.1481): Trung bình, mô hình dự đoán nhiệt độ lệch khoảng 4.15 độ C so với nhiệt độ thực tế. Đây là một con số tương đối lớn khi dự báo nhiệt độ, gợi ý rằng mô hình tuyến tính có thể chưa đủ để nắm bắt các biến động phức tạp của nhiệt độ.

RMSE (5.4597): Tương tự như MAE, RMSE cũng cho thấy sai số trung bình là khoảng 5.46 độ C. Giá trị RMSE cao hơn MAE là điều bình thường vì RMSE phạt nặng hơn các sai số lớn.

MSE (29.8082): Giá trị MSE khá cao, cho thấy có những dự đoán với sai số lớn.

Khả năng giải thích của mô hình (R2 Score):


R2 Score (0.3204): Chỉ số R2 là 0.3204 (tức khoảng 32.04%). Điều này có nghĩa là mô hình Linear Regression chỉ có thể giải thích được khoảng 32.04% sự biến thiên của nhiệt độ trong tập dữ liệu kiểm tra.

Một R2 Score là 0.32 cho thấy mô hình tuyến tính không hoàn toàn phù hợp để giải thích mối quan hệ giữa các đặc trưng đầu vào và nhiệt độ. Điều này ngụ ý rằng mối quan hệ này có thể không tuyến tính, hoặc có nhiều yếu tố phức tạp, phi tuyến tính khác đang ảnh hưởng đến nhiệt độ mà mô hình tuyến tính không thể nắm bắt được.

Kết luận về Baseline:

Mô hình Linear Regression cung cấp một baseline cơ bản nhưng cho thấy hiệu suất còn hạn chế trong việc dự báo nhiệt độ dựa trên tập dữ liệu này. Sai số dự đoán trung bình còn khá cao (hơn 4 độ C), và khả năng giải thích sự biến thiên của nhiệt độ chỉ đạt khoảng 32%. Điều này chỉ ra rằng cần phải sử dụng các mô hình phức tạp hơn, có khả năng nắm bắt các mối quan hệ phi tuyến tính tốt hơn để đạt được độ chính xác cao hơn cho bài toán dự báo thời tiết (nhiệt độ).

** Phân tích lại kết quả của Mô hình Decision Tree Regressor:*



Kết quả các chỉ số bị ẩn do nền tảng.

Nhận xét:

Hiệu suất của Decision Tree Regressor:

MAE (2.4578): Giá trị sai số tuyệt đối trung bình là khoảng 2.46 độ C. Điều này có nghĩa là trung bình, dự đoán nhiệt độ của mô hình Decision Tree lệch khoảng 2.46 độ C so với nhiệt độ thực tế.

RMSE (3.3516): Giá trị RMSE là khoảng 3.35 độ C. Tương tự như MAE, đây là thước đo sai số dự đoán, và vì RMSE phạt nặng hơn các sai số lớn, nên giá trị của nó thường cao hơn MAE.

R2 Score (0.7483): Chỉ số R2 đạt 0.7483, tức là khoảng 74.83%. Điều này cho thấy mô hình Decision Tree có khả năng giải thích gần 75% sự biến thiên của nhiệt độ

trong tập dữ liệu kiểm tra. Đây là một mức R^2 khá tốt, chỉ ra rằng mô hình đã học được các mối quan hệ quan trọng từ dữ liệu để đưa ra dự đoán.

Khả năng học hỏi mối quan hệ phi tuyến tính:

Decision Tree là một mô hình phi tuyến tính có khả năng phân chia không gian dữ liệu thành các vùng dựa trên các luật quyết định. Điều này cho phép nó nắm bắt các mối quan hệ phức tạp và phi tuyến tính giữa các đặc trưng đầu vào và nhiệt độ. Kết quả R^2 Score 0.7483 minh chứng cho khả năng này.


Hạn chế tiềm năng của Decision Tree đơn lẻ:

Mặc dù có hiệu suất tốt, các cây quyết định đơn lẻ có thể dễ bị quá khớp (overfitting) với dữ liệu huấn luyện, đặc biệt nếu cây quá sâu (không bị giới hạn bởi `max_depth`). Điều này có nghĩa là mô hình có thể hoạt động rất tốt trên dữ liệu đã thấy (tập huấn luyện) nhưng lại kém hiệu quả hơn trên dữ liệu mới (tập kiểm tra) nếu không được điều chỉnh cẩn thận.

Kết luận về Decision Tree Regressor:

Mô hình Decision Tree Regressor đã thể hiện khả năng khá tốt trong việc dự báo thời tiết (cụ thể là nhiệt độ) với sai số MAE khoảng 2.46 độ C và khả năng giải thích gần 75% sự biến thiên của nhiệt độ (R^2 Score). Đây là một mô hình phi tuyến tính hiệu quả cho bài toán này, cho thấy nó học được các mẫu phức tạp trong dữ liệu.

** Phân tích kết quả của Mô hình Random Forest Regressor:*



Kết quả các chỉ số bị ẩn do nền tảng.

Nhận xét:

Độ chính xác cao:

MAE (1.8398): Sai số tuyệt đối trung bình của Random Forest là khoảng 1.84 độ C. Điều này cho thấy mô hình dự đoán nhiệt độ rất chính xác, với sai số trung bình thực tế chỉ dưới 2 độ C.

RMSE (2.6155): Tương tự, RMSE cũng rất thấp, cho thấy mô hình này ít tạo ra các lỗi lớn và duy trì độ chính xác cao trên toàn bộ tập kiểm tra.

Khả năng giải thích của mô hình (R2 Score):

R2 Score (0.8496): Chỉ số R2 đạt 0.8496, tức là khoảng 84.96%. Điều này có nghĩa là mô hình Random Forest có khả năng giải thích gần 85% sự biến thiên của nhiệt độ trong tập dữ liệu kiểm tra. Đây là một mức R2 rất cao, minh chứng cho sức mạnh của thuật toán này trong việc nắm bắt các mối quan hệ phức tạp và phi tuyến tính trong dữ liệu thời tiết.

Sức mạnh của kỹ thuật Ensemble:

Random Forest là một thuật toán "ensemble" xây dựng nhiều cây quyết định độc lập trên các tập con dữ liệu và đặc trưng ngẫu nhiên. Sau đó, nó tổng hợp các dự đoán của từng cây (bằng cách lấy trung bình đối với bài toán hồi quy). Kỹ thuật này giúp giảm thiểu vấn đề quá khớp (overfitting) thường gặp ở các cây quyết định đơn lẻ và tăng cường khả năng tổng quát hóa của mô hình trên dữ liệu chưa từng thấy.

* Kết luận về Random Forest Regressor:

Mô hình Random Forest Regressor đã chứng tỏ hiệu suất rất mạnh mẽ trong việc dự báo thời tiết (cụ thể là nhiệt độ). Với MAE rất thấp và R2 Score gần 85%, đây là một mô hình đáng tin cậy và hiệu quả cao cho bài toán này, cho thấy ưu điểm rõ ràng của việc sử dụng các thuật toán ensemble.

Phân tích kết quả đánh giá mức độ phù hợp của mô hình Multiple Linear Regression:

```
Mean absolute error: 1.20
Residual sum of squares (MSE): 2.51
R2-score: 0.96
```

Mean Absolute Error (MAE): 1.20

Ý nghĩa: MAE đo lường độ lớn trung bình của các lỗi giữa các giá trị dự đoán và các giá trị thực tế. Nó cho biết mức độ trung bình mà các dự đoán của mô hình "lệch" khỏi các giá trị thực tế, không quan tâm đến hướng của lỗi.

Phân tích: Một MAE là 1.20 có nghĩa là, trung bình, các dự đoán của mô hình sai lệch so với giá trị thực tế khoảng 1.20 đơn vị. Để đánh giá xem 1.20 là tốt hay không, cần xem xét thang đo của biến mục tiêu (test_y). Nếu biến mục tiêu có giá trị trong khoảng nhỏ (ví dụ từ 0 đến 10), thì 1.20 có thể là một lỗi tương đối lớn. Tuy nhiên, nếu biến mục tiêu có giá trị trong khoảng lớn (ví dụ từ 0 đến 1000), thì 1.20 là một lỗi rất nhỏ và cho thấy mô hình khá chính xác.

Residual Sum of Squares (MSE): 2.51

Ý nghĩa: MSE đo lường bình phương trung bình của các lỗi. Bằng cách bình phương các lỗi, MSE đặt trọng số lớn hơn vào các lỗi lớn, làm cho nó nhạy cảm hơn với các ngoại lệ so với MAE.

Phân tích: MSE là 2.51. Tương tự như MAE, giá trị này cần được đánh giá trong bối cảnh thang đo của dữ liệu. Một MSE thấp cho thấy các điểm dữ liệu phù hợp chặt chẽ với đường hồi quy của mô hình. Trong trường hợp này, 2.51 cho thấy rằng bình phương trung bình của sự khác biệt giữa các giá trị dự đoán và thực tế là 2.51.

R2-score (Hệ số xác định): 0.96

Ý nghĩa: R2-score là một chỉ số quan trọng để đánh giá mức độ phù hợp của mô hình hồi quy tuyến tính. Nó biểu thị tỷ lệ phương sai trong biến phụ thuộc ($test_y$) có thể được giải thích bởi các biến độc lập trong mô hình. R2-score nằm trong khoảng từ 0 đến 1.

R2 = 0: Mô hình không giải thích được bất kỳ phương sai nào của biến phụ thuộc.

R2 = 1: Mô hình giải thích được 100% phương sai của biến phụ thuộc (mô hình hoàn hảo).

Phân tích: Một R2-score là 0.96 là một kết quả rất tốt. Điều này có nghĩa là mô hình Multiple Linear Regression giải thích được 96% sự biến thiên của biến phụ thuộc ($test_y$). Nói cách khác, 96% sự thay đổi trong biến mục tiêu có thể được dự đoán từ các biến độc lập trong mô hình. Đây là một dấu hiệu mạnh mẽ cho thấy mô hình có khả năng giải thích và dự đoán tốt.

Tổng kết đánh giá mức độ phù hợp của mô hình:

Dựa trên các chỉ số trên, mô hình Multiple Linear Regression có vẻ rất phù hợp và mạnh mẽ:

R2-score cao (0.96) cho thấy mô hình có khả năng giải thích phần lớn sự biến động của biến phụ thuộc.

MAE (1.20) và MSE (2.51), nếu so với thang đo của biến mục tiêu, có khả năng là các lỗi dự đoán chấp nhận được, đặc biệt khi kết hợp với R2-score cao.

*** Phân tích giá hiệu quả của mô hình Decision Tree Regression:**

```
Mean absolute error: 0.56
Residual sum of squares (MSE): 1.12
R2-score: 0.98
```

Mean Absolute Error (MAE): 0.56

Ý nghĩa: MAE là giá trị trung bình của độ lớn các lỗi giữa giá trị dự đoán và giá trị thực tế. Nó cho biết trung bình mô hình dự đoán sai lệch bao nhiêu so với giá trị thực tế.

Phân tích: MAE là 0.56. So với MAE của mô hình Multiple Linear Regression trước đó (1.20), MAE của Decision Tree Regression thấp hơn đáng kể. Điều này ngụ ý

rằng, trung bình, các dự đoán của mô hình Decision Tree Regression gần với giá trị thực tế hơn so với mô hình Hồi quy Tuyến tính Đa biến. Một giá trị 0.56 cho thấy các lỗi dự đoán tương đối nhỏ, nhưng mức độ "tốt" thực sự của nó còn phụ thuộc vào thang đo của biến mục tiêu ($test_y$).

Residual Sum of Squares (MSE): 1.12

Ý nghĩa: MSE là trung bình của bình phương các lỗi. Nó khuếch đại các lỗi lớn hơn và giúp nhận diện các điểm dữ liệu mà mô hình dự đoán kém chính xác.

Phân tích: MSE là 1.12. So với MSE của mô hình Multiple Linear Regression (2.51), MSE của Decision Tree Regression cũng thấp hơn đáng kể. Giá trị MSE thấp hơn này củng cố nhận định rằng mô hình Decision Tree Regression có các lỗi dự đoán nhỏ hơn và ít lỗi lớn hơn so với mô hình hồi quy tuyến tính.

R2-score (Hệ số xác định): 0.98

Ý nghĩa: R2-score (hay hệ số xác định) cho biết tỷ lệ phương sai trong biến phụ thuộc ($test_y$) có thể được giải thích bởi mô hình. Giá trị này nằm trong khoảng từ 0 đến 1, với giá trị càng gần 1 càng tốt.

Phân tích: Một R2-score là 0.98 là một kết quả xuất sắc. Điều này có nghĩa là mô hình Decision Tree Regression giải thích được 98% sự biến thiên của biến phụ thuộc ($test_y$). So với R2-score của mô hình Multiple Linear Regression (0.96), mô hình Decision Tree Regression thậm chí còn tốt hơn một chút trong việc giải thích dữ liệu. Đây là một dấu hiệu rất mạnh mẽ cho thấy mô hình có khả năng phù hợp với dữ liệu và dự đoán rất tốt.

Tổng kết đánh giá hiệu quả của mô hình Decision Tree Regression:

Mô hình Decision Tree Regression cho thấy hiệu suất rất cao và vượt trội trong việc dự đoán:

R2-score cực kỳ cao (0.98) chỉ ra rằng mô hình giải thích được gần như toàn bộ sự biến động của biến phụ thuộc.

MAE (0.56) và MSE (1.12) rất thấp so với các giá trị của mô hình hồi quy tuyến tính trước đó, cho thấy các dự đoán của mô hình rất gần với giá trị thực tế và có ít lỗi lớn.

* *Phân tích độ chính xác của mô hình Random Forest Regression:*

```
Mean absolute error: 0.47  
Residual sum of squares (MSE): 0.63  
R2-score: 0.99
```

Mean Absolute Error (MAE): 0.47

Ý nghĩa: MAE là giá trị trung bình của độ lớn các lỗi giữa giá trị dự đoán và giá trị thực tế. Nó cho biết trung bình mô hình dự đoán sai lệch bao nhiêu so với giá trị thực tế.

Phân tích: MAE là 0.47. Đây là giá trị MAE thấp nhất trong số ba mô hình bạn đã đánh giá (so với 1.20 của Hồi quy tuyến tính và 0.56 của Cây quyết định). Điều này cho thấy mô hình Random Forest Regression tạo ra các dự đoán gần với giá trị thực tế nhất, với sai số trung bình chỉ là 0.47 đơn vị. Đây là một kết quả rất tốt, cho thấy mô hình có độ chính xác cao.

Residual Sum of Squares (MSE): 0.63

Ý nghĩa: MSE là trung bình của bình phương các lỗi. Nó khuếch đại các lỗi lớn hơn và giúp nhận diện các điểm dữ liệu mà mô hình dự đoán kém chính xác.

Phân tích: MSE là 0.63. Đây cũng là giá trị MSE thấp nhất so với hai mô hình trước (2.51 của Hồi quy tuyến tính và 1.12 của Cây quyết định). MSE thấp cho thấy rằng không chỉ các lỗi trung bình là nhỏ mà mô hình còn tránh được các lỗi lớn một cách hiệu quả hơn. Đây là một dấu hiệu tích cực về hiệu suất của mô hình.

R2-score (Hệ số xác định): 0.99

Ý nghĩa: R2-score (hay hệ số xác định) cho biết tỷ lệ phương sai trong biến phụ thuộc ($test_y$) có thể được giải thích bởi mô hình. Giá trị này nằm trong khoảng từ 0 đến 1, với giá trị càng gần 1 càng tốt.

Phân tích: Một R2-score là 0.99 là một kết quả cực kỳ xuất sắc và gần như hoàn hảo. Điều này có nghĩa là mô hình Random Forest Regression giải thích được 99% sự biến thiên của biến phụ thuộc ($test_y$). Đây là giá trị R2-score cao nhất trong số ba mô hình bạn đã thử nghiệm, cho thấy Random Forest là mô hình có khả năng giải thích dữ liệu tốt nhất trong trường hợp này.

Tổng kết đánh giá độ chính xác của mô hình Random Forest Regression:

Mô hình Random Forest Regression thể hiện độ chính xác và hiệu quả vượt trội trên tập dữ liệu này:

R2-score cực cao (0.99) chứng tỏ mô hình có khả năng giải thích gần như toàn bộ sự biến động của biến phụ thuộc, cho thấy nó nắm bắt được các mối quan hệ phức tạp trong dữ liệu rất tốt.

MAE (0.47) và MSE (0.63) cực thấp xác nhận rằng các dự đoán của mô hình rất sát với giá trị thực tế và có sai số rất nhỏ.

So sánh và Kết luận chung:

Dựa trên các chỉ số hiệu suất, Random Forest Regression là mô hình vượt trội nhất trong ba mô hình được thử nghiệm cho bài toán này. Nó đạt được điểm R2-score cao nhất (0.99), đồng thời có MAE và MSE thấp nhất, cho thấy các dự đoán của nó là chính xác nhất và có ít lỗi lớn nhất.

Thứ tự hiệu quả từ thấp đến cao là: Multiple Linear Regression < Decision Tree Regression < Random Forest Regression.

3. Hàm ý và Khuyến nghị:

Khả năng tổng quát hóa: Việc đạt được R2-score rất cao (0.99) với Random Forest Regression là một tín hiệu tích cực. Tuy nhiên, cần thận trọng kiểm tra khả năng tổng quát hóa của mô hình trên dữ liệu mới hoàn toàn (chưa từng được thấy) để đảm bảo không xảy ra hiện tượng quá khớp (overfitting), đặc biệt khi các mô hình ensemble như Random Forest có khả năng học rất phức tạp.

Kiểm định chéo (Cross-validation): Để có đánh giá tin cậy hơn về hiệu suất của mô hình Random Forest, nên sử dụng các kỹ thuật kiểm định chéo (ví dụ: K-fold cross-validation) thay vì chỉ đánh giá trên một tập test_y duy nhất. Điều này sẽ giúp ước tính ổn định hơn về hiệu suất tổng thể của mô hình.

Lựa chọn mô hình: Nếu mục tiêu chính là đạt được độ chính xác dự đoán cao nhất và bạn không quá quan trọng về khả năng diễn giải mô hình (interpretability), thì Random Forest Regression là lựa chọn tốt nhất dựa trên kết quả hiện tại.

Phân tích sâu hơn: Nếu có thể, hãy xem xét các biểu đồ phần dư (residual plots) của các mô hình để phát hiện bất kỳ sai lệch hệ thống nào trong dự đoán hoặc các giả định không được đáp ứng.

* Phân tích kết quả Siêu Tham số cho GradientBoostingRegressor:

```
Lưới siêu tham số sẽ được tìm kiếm cho GradientBoostingRegressor:
n_estimators: [100, 200]
learning_rate: [0.05, 0.1]
max_depth: [3, 5]
min_samples_split: [2, 5]
subsample: [0.8, 1.0]

Tổng số tổ hợp siêu tham số mới: 32
Tổng số lần huấn luyện mô hình với cv=3: 96
```

Để tối ưu hóa hiệu suất của mô hình GradientBoostingRegressor, một quy trình tìm kiếm lưới (Grid Search) đã được thiết lập.

Mô hình mục tiêu:

GradientBoostingRegressor đã được chọn, với random_state=42 được thiết lập để đảm bảo tính lặp lại của kết quả. Gradient Boosting là một thuật toán ensemble mạnh mẽ, thường mang lại hiệu suất cao trong các bài toán hồi quy.

Lưới siêu tham số (param_grid_gbr) định nghĩa cho quá trình tìm kiếm:

n_estimators: [100, 200]

Xác định số lượng cây yếu (weak learners) trong tập hợp. Việc kiểm tra hai giá trị này giúp đánh giá ảnh hưởng của số lượng cây đến hiệu suất và thời gian huấn luyện.

learning_rate: [0.05, 0.1]

Kiểm soát tốc độ học hay trọng số đóng góp của mỗi cây vào tổng thể. Các giá trị nhỏ hơn thường yêu cầu nhiều cây hơn nhưng có thể dẫn đến mô hình vững chắc hơn.

max_depth: [3, 5]

Giới hạn độ sâu tối đa của mỗi cây thành phần. Độ sâu nhỏ giúp kiểm soát độ phức tạp và ngăn chặn quá khớp của từng cây.

min_samples_split: [2, 5]

Xác định số lượng mẫu tối thiểu cần thiết để một nút trong cây có thể phân tách. Giá trị lớn hơn giúp làm mịn mô hình và giảm quá khớp.

subsample: [0.8, 1.0]

Xác định tỷ lệ mẫu được lấy ngẫu nhiên (không lặp lại) để huấn luyện mỗi cây con. Việc sử dụng subsample nhỏ hơn 1.0 (ví dụ 0.8) được gọi là Stochastic Gradient Boosting, giúp giảm phương sai và nguy cơ quá khớp.

Tính toán Số lượng Tổ hợp và Lần Huấn luyện:

Tổng số tổ hợp siêu tham số mới: 32

Tính toán dựa trên số lượng giá trị được định nghĩa cho mỗi siêu tham số ($2 * 2 * 2 * 2 * 2 = 32$). Điều này có nghĩa là 32 cấu hình tham số khác nhau sẽ được thử nghiệm.

Tổng số lần huấn luyện mô hình với $cv=3$: 96

Với mỗi tổ hợp tham số, mô hình sẽ được huấn luyện 3 lần do sử dụng kiểm định chéo với 3 fold ($32 \text{ tổ hợp} * 3 \text{ fold} = 96 \text{ lần huấn luyện}$). Điều này đảm bảo đánh giá hiệu suất của mỗi tổ hợp tham số một cách đáng tin cậy hơn, giảm thiểu sự phụ thuộc vào việc chia tập dữ liệu cụ thể.

Kết luận về Quy trình Tối ưu hóa:

Việc thiết lập lưới siêu tham số này là một phương pháp tiếp cận có hệ thống để tìm kiếm các tham số tối ưu cho mô hình GradientBoostingRegressor. Các phạm vi giá trị được chọn là hợp lý và thường được sử dụng trong thực tế. Số lượng tổ hợp và số lần huấn luyện là khả thi về mặt tính toán, đồng thời việc sử dụng kiểm định chéo giúp đảm bảo tính vững chắc của kết quả tối ưu. Bước tiếp theo sẽ là thực hiện quá trình tìm kiếm lưới để xác định bộ siêu tham số tốt nhất.

* Phân tích kết quả Đánh giá Mô hình GradientBoostingRegressor:

```
Bắt đầu tìm kiếm siêu tham số tốt nhất cho GradientBoostingRegressor...
Fitting 5 folds for each of 32 candidates, totalling 160 fits
Tìm kiếm hoàn tất.
```

```
Siêu tham số tốt nhất tìm được cho GradientBoostingRegressor:
{'learning_rate': 0.1, 'max_depth': 5, 'min_samples_split': 2, 'n_estimators': 200, 'subsample': 0.8}
Điểm số tốt nhất (CV) (sử dụng 'neg_mean_squared_error'): -0.5391
RMSE tốt nhất (CV): 0.7342
```

```
Đánh giá mô hình GradientBoostingRegressor đã tối ưu trên tập kiểm tra:
MAE (tập test): 0.5126
MSE (tập test): 0.6604
RMSE (tập test): 0.8127
R2 Score (tập test): 0.9908
```

Quá trình tối ưu hóa siêu tham số cho mô hình GradientBoostingRegressor đã được thực hiện bằng cách sử dụng kỹ thuật tìm kiếm lưới (Grid Search) kết hợp với kiểm định chéo (Cross-Validation). Mục tiêu là xác định bộ siêu tham số tối ưu giúp mô hình đạt hiệu suất cao nhất.

+ Cấu hình Tìm kiếm Siêu Tham số:

Mô hình: GradientBoostingRegressor

Các Siêu Tham số được Tìm kiếm và Phạm vi Giá trị:

n_estimators: [100, 200] (Số lượng cây quyết định)

learning_rate: [0.05, 0.1] (Tốc độ học)

max_depth: [3, 5] (Độ sâu tối đa của mỗi cây)

min_samples_split: [2, 5] (Số lượng mẫu tối thiểu để phân tách nút)

subsample: [0.8, 1.0] (Tỷ lệ mẫu con để huấn luyện mỗi cây)

Số lượng Tổ hợp Siêu Tham số: 32 tổ hợp

Kiểm định Chéo (Cross-Validation): 5 folds (cv=5)

Tổng số lần huấn luyện mô hình: 32 tổ hợp * 5 folds = 160 lần.

+ Kết quả Tìm kiếm Siêu Tham số Tốt nhất (Trên Tập Huấn luyện với CV):

Quá trình tìm kiếm đã hoàn tất và xác định được bộ siêu tham số tối ưu dựa trên điểm số kiểm định chéo:

Siêu Tham số Tốt nhất:

learning_rate: 0.1

max_depth: 5

min_samples_split: 2

n_estimators: 200

subsample: 0.8

Điểm số Tốt nhất (CV) (sử dụng 'neg_mean_squared_error'): -0.5391

Điểm số này là giá trị âm của MSE (Mean Squared Error) trung bình trên các fold kiểm định chéo. Mục tiêu là tối đa hóa điểm số này (tức là giảm thiểu MSE).

RMSE Tốt nhất (CV): 0.7342

Giá trị Căn bậc hai Sai số Bình phương Trung bình (RMSE) tương ứng trên các fold kiểm định chéo là 0.7342. RMSE là một chỉ số hữu ích để đánh giá lỗi dự đoán trong cùng đơn vị với biến mục tiêu.

+ Đánh giá Mô hình Đã Tối ưu trên Tập Kiểm tra Độc lập:

Sau khi xác định được bộ siêu tham số tốt nhất, mô hình GradientBoostingRegressor đã được huấn luyện lại với các tham số này và đánh giá trên tập kiểm tra độc lập (test set) để đo lường khả năng tổng quát hóa của nó.

MAE (tập test): 0.5126

Sai số tuyệt đối trung bình trên tập kiểm tra là 0.5126. Giá trị này cho thấy mức độ sai lệch trung bình của các dự đoán so với giá trị thực tế.

MSE (tập test): 0.6604

Sai số bình phương trung bình trên tập kiểm tra là 0.6604.

RMSE (tập test): 0.8127

Căn bậc hai sai số bình phương trung bình trên tập kiểm tra là 0.8127.

R2 Score (tập test): 0.9908

Hệ số xác định R2 trên tập kiểm tra là 0.9908. Điều này có nghĩa là mô hình GradientBoostingRegressor đã tối ưu có khả năng giải thích 99.08% sự biến thiên của biến phụ thuộc trên dữ liệu chưa từng thấy.

+ Nhận xét và Kết luận:

Quá trình tối ưu hóa đã thành công trong việc tìm ra bộ siêu tham số tối ưu cho GradientBoostingRegressor. Các kết quả đánh giá trên tập kiểm tra độc lập cho thấy hiệu suất của mô hình đã tối ưu là cực kỳ cao và ấn tượng:

R2 Score (0.9908): Giá trị này cho thấy mô hình có khả năng phù hợp gần như hoàn hảo với dữ liệu và giải thích phần lớn sự biến động của biến mục tiêu. Đây là một chỉ số rất mạnh về hiệu suất dự đoán.

MAE (0.5126), MSE (0.6604), RMSE (0.8127): Các chỉ số lỗi này đều rất thấp, xác nhận rằng các dự đoán của mô hình rất gần với các giá trị thực tế, với sai số trung bình nhỏ và ít lỗi lớn.

So sánh với các mô hình đã đánh giá trước đó (Multiple Linear Regression, Decision Tree Regression, Random Forest Regression), GradientBoostingRegressor đã tối ưu đạt được hiệu suất tương đương hoặc thậm chí vượt trội so với Random Forest Regression ($R^2 = 0.99$ so với 0.9908).

Tuy nhiên, với một R^2 -score cao đến mức này, việc thận trọng kiểm tra khả năng quá khớp (overfitting) là cần thiết. Mặc dù kiểm định chéo đã được sử dụng trong quá trình tối ưu hóa, việc thử nghiệm mô hình trên một tập dữ liệu hoàn toàn mới trong môi trường thực tế (nếu có) sẽ cung cấp xác nhận cuối cùng về khả năng tổng quát hóa của nó.

VI. Kết luận

Dự án này tập trung phát triển và đánh giá các mô hình hồi quy nhằm dự đoán nhiệt độ (tempC) dựa trên dữ liệu thời tiết thu thập từ Kanpur, Ấn Độ. Bốn mô hình chính đã được triển khai và so sánh: Multiple Linear Regression, Decision Tree Regression, Random Forest Regression và Gradient Boosting Regressor (GBR) với tối ưu hóa siêu tham số.

Tóm tắt Kết quả Chính:

Dữ liệu: Bao gồm các đặc trưng như nhiệt độ tối đa, nhiệt độ tối thiểu, độ che phủ mây, độ ẩm, giờ nắng, chỉ số nhiệt, lượng mưa, áp suất và tốc độ gió. Biến mục tiêu là nhiệt độ trung bình (tempC). Dữ liệu đã được tiền xử lý, chia thành tập huấn luyện và kiểm tra, đồng thời chuẩn hóa các đặc trưng số.

Hiệu suất mô hình:

Multiple Linear Regression: $R^2 = 0.96$, MAE = 1.20, MSE = 2.51. Mô hình giải thích khá tốt sự biến thiên của nhiệt độ nhưng hạn chế với các mối quan hệ phi tuyến.

Decision Tree Regression: $R^2 = 0.98$, MAE = 0.56, MSE = 1.12, cho thấy khả năng nắm bắt các mối quan hệ phi tuyến tốt hơn.

Random Forest Regression: $R^2 = 0.99$, MAE = 0.47, MSE = 0.63, thể hiện độ chính xác dự đoán cao và giải thích gần như toàn bộ sự biến động của nhiệt độ.

Gradient Boosting Regressor (tối ưu hóa): $R^2 = 0.9908$, MAE = 0.5126, MSE = 0.6604, RMSE = 0.8127. Các siêu tham số tối ưu gồm: $n_estimators=200$, $learning_rate=0.1$, $max_depth=5$, $min_samples_split=2$, $subsample=0.8$.

Kết luận chung:

Các mô hình Random Forest Regression và Gradient Boosting Regressor (sau tối ưu hóa) cho thấy hiệu suất vượt trội với R^2 gần 0.99, chứng tỏ khả năng nắm bắt mối quan hệ phức tạp trong dữ liệu thời tiết tốt hơn đáng kể so với mô hình tuyến tính đơn giản. Kết quả này cho thấy các mô hình ensemble dựa trên cây quyết định có thể áp dụng hiệu quả trong dự báo nhiệt độ thực tế.

Hạn chế:

Nguy cơ quá khớp: Mặc dù R^2 cao, vẫn tồn tại nguy cơ overfitting, đặc biệt với các mô hình phức tạp. Đánh giá trên dữ liệu hoàn toàn mới là cần thiết để xác nhận khả năng tổng quát hóa.

Chất lượng dữ liệu: Báo cáo chưa đề cập chi tiết việc xử lý giá trị thiếu hoặc ngoại lai, điều này có thể ảnh hưởng đến hiệu suất mô hình.

Thời gian huấn luyện: Các mô hình ensemble, đặc biệt khi tối ưu hóa siêu tham số với Grid Search và Cross-Validation, yêu cầu tài nguyên tính toán và thời gian đáng kể.

Hướng phát triển:

Tiền xử lý nâng cao: Xử lý giá trị thiếu và ngoại lai để làm sạch dữ liệu.

Feature Engineering: Tạo đặc trưng mới từ dữ liệu hiện có, ví dụ: nhiệt độ trung bình ngày, chênh lệch nhiệt độ ngày–đêm, chỉ số kết hợp độ ẩm và nhiệt độ.

Khám phá thuật toán mới: Thử nghiệm các mô hình tiên tiến như XGBoost, LightGBM, hoặc Neural Networks nếu dữ liệu đủ lớn và phức tạp.

Tối ưu hóa siêu tham số nâng cao: Sử dụng Randomized Search CV hoặc Bayesian Optimization để khám phá không gian siêu tham số hiệu quả hơn.

Phân tích độ nhạy mô hình: Nghiên cứu tác động của từng đặc trưng đầu vào đến dự đoán, giúp hiểu rõ các yếu tố ảnh hưởng chính đến nhiệt độ.

Tổng kết, dự án đã chứng minh khả năng ứng dụng AI/Học máy trong dự báo nhiệt độ, đồng thời cung cấp nền tảng để phát triển các nghiên cứu và ứng dụng nâng cao trong tương lai.

VII. Tài liệu Tham khảo

Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems* (2nd ed.). O'Reilly Media.

McKinney, W. (2017). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython* (2nd ed.). O'Reilly Media.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Joly, A., Passos, D., Cournapeau, A., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics*, 29(5), 1189–1232.

Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.

World Weather Online. (n.d.). *Historical Weather Data for Kanpur, India*.

ThS. Trần Đình Tân. *Giáo trình môn học Nhập môn Trí tuệ Nhân tạo*, Trường Đại học Phenikaa.

VIII. Lời cảm ơn

Để hoàn thành báo cáo này, chúng em xin bày tỏ lòng biết ơn sâu sắc đến những cá nhân và tổ chức đã hỗ trợ và tạo điều kiện thuận lợi trong suốt quá trình thực hiện dự án.

Trước hết, chúng em xin gửi lời cảm ơn chân thành đến *ThS. Trần Đình Tân*, giảng viên môn *Nhập môn Trí tuệ Nhân tạo*, đã tận tình giảng dạy, truyền đạt kiến thức chuyên sâu và cung cấp những hướng dẫn quý báu. Những bài giảng và góp ý của thầy không chỉ là nền tảng vững chắc cho việc triển khai các mô hình mà còn là nguồn cảm hứng để chúng em khám phá sâu hơn về lĩnh vực này.

Chúng em cũng xin cảm ơn *Trường Đại học Phenikaa* đã tạo điều kiện về môi trường học tập và cung cấp các tài nguyên cần thiết, giúp quá trình nghiên cứu diễn ra hiệu quả.

Chúng em xin chân thành cảm ơn!

Trân trọng,