

TRƯỜNG ĐẠI HỌC PHENIKAA

-----oOo-----



**Xây dựng mô hình học sâu để phân loại ảnh X-ray
phát hiện viêm phổi**

Course/Học phần: Học Sâu

Code/Mã học phần: EEE703035

Class/Lớp : N01

Instructor/Giảng viên: TS. Lê Minh Huy

Group/Nhóm : Trương Văn Diệu

HÀ NỘI – 2025

DANH SÁCH THÀNH VIÊN TRONG NHÓM

TT	Họ và tên	Lớp -khóa- ngành	Email	Điện thoại	Mã sinh viên	Mức độ đóng góp (theo thang điểm 10)
1	Trương Văn Diệu	K17_KHMT_1	23017208@st.phenikaa- uni.edu.vn	0983078205	23017208	10

MỤC LỤC

I. Giới thiệu	4
1.1. Bối cảnh và động lực	4
1.2. Mục tiêu đề tài.....	5
1.3. Các đóng góp của bài báo cáo.....	6
II. Phát biểu bài toán.....	6
2.1. Mô tả bài toán.....	6
2.2. Biểu diễn toán học.....	7
2.3. Thách thức của bài toán	8
III. Nghiên cứu liên quan	9
3.1. Phương pháp truyền thống	9
3.2. Phương pháp học sâu hiện đại	10
3.3. Nhận xét, hạn chế và định hướng tiếp cận của đề tài	11
IV. Phương pháp đề xuất	12
4.1. Ý tưởng tổng quát	12
4.2. Mô hình học sâu 5 lớp xây dựng từ đầu	13
4.3. Thuật toán huấn luyện và lan truyền ngược	15
4.4. Phân tích độ phức tạp.....	17
4.5. Hình minh họa mô hình	19
V. Kết quả thực nghiệm.....	21
5.1. Cấu hình thực nghiệm.....	21
5.2. Baseline so sánh	23
5.3. Dữ liệu sử dụng	24
5.4. Tiêu chí đánh giá.....	26
5.5. Phân tích kết quả thực nghiệm.....	28
VI. Kết luận và hướng phát triển	30
6.1. Kết luận	31
6.2. Hướng phát triển	31
VII. Tài liệu tham khảo	32
VIII. Lời cảm ơn	32

I. Giới thiệu

1.1. Bối cảnh và động lực

Trong những năm gần đây, học sâu (Deep Learning) đã trở thành một trong những hướng nghiên cứu và ứng dụng quan trọng nhất trong lĩnh vực trí tuệ nhân tạo, đặc biệt là trong các bài toán liên quan đến xử lý ảnh và thị giác máy tính. Nhờ khả năng tự động trích xuất đặc trưng và học các biểu diễn phức tạp từ dữ liệu, các mô hình học sâu đã đạt được nhiều thành tựu vượt trội so với các phương pháp học máy truyền thống trong nhiều lĩnh vực như nhận dạng hình ảnh, xử lý ngôn ngữ tự nhiên và y sinh học.

Trong lĩnh vực chẩn đoán y khoa, việc phân tích ảnh X-ray lồng ngực đóng vai trò quan trọng trong việc hỗ trợ phát hiện sớm các bệnh lý về phổi, đặc biệt là viêm phổi (Pneumonia). Viêm phổi là một trong những nguyên nhân gây tử vong hàng đầu trên toàn thế giới, nhất là ở trẻ em và người cao tuổi. Việc chẩn đoán chính xác và kịp thời thông qua ảnh X-ray không chỉ giúp nâng cao hiệu quả điều trị mà còn giảm tải cho đội ngũ y bác sĩ trong bối cảnh khối lượng bệnh nhân ngày càng gia tăng.

Các phương pháp truyền thống trong phân loại ảnh y tế thường dựa trên đặc trưng thủ công (handcrafted features) kết hợp với các thuật toán học máy như SVM, KNN hay Logistic Regression. Tuy nhiên, các phương pháp này phụ thuộc nhiều vào kinh nghiệm thiết kế đặc trưng và thường không đạt hiệu quả cao khi đối mặt với dữ liệu có tính phức tạp và biến thiên lớn như ảnh X-ray. Sự ra đời của các mô hình học sâu, đặc biệt là mạng nơ-ron nhiều lớp, đã mở ra hướng tiếp cận mới với khả năng học trực tiếp từ dữ liệu thô mà không cần thiết kế đặc trưng thủ công.

Mặc dù vậy, trong quá trình học tập và giảng dạy môn Fundamental of Deep Learning, việc chỉ sử dụng các thư viện học sâu sẵn có như TensorFlow hay PyTorch có thể khiến người học dễ rơi vào tình trạng “sử dụng công cụ” mà chưa thực sự hiểu rõ bản chất bên trong của các thuật toán học sâu. Điều này làm hạn chế khả năng phân tích, điều chỉnh mô hình cũng như mở rộng nghiên cứu trong các bài toán thực tế.

Xuất phát từ bối cảnh đó, bài báo cáo này được thực hiện với mục tiêu xây dựng và huấn luyện một mô hình học sâu từ đầu (from scratch), không sử dụng các thư viện học sâu có sẵn, nhằm giúp người học hiểu rõ hơn về các thành phần cốt lõi của một mô hình học sâu, bao gồm quá trình lan truyền xuôi, lan truyền ngược, hàm mất mát và thuật toán tối ưu. Việc áp dụng mô hình này cho bài toán phân loại ảnh X-ray viêm phổi không chỉ mang ý nghĩa thực tiễn mà còn giúp củng cố nền tảng lý thuyết và kỹ năng cài đặt học sâu một cách bài bản.

1.2. Mục tiêu đề tài

Mục tiêu chính của đề tài này là *xây dựng và huấn luyện một mô hình học sâu từ đầu (from scratch)* nhằm giải quyết bài toán phân loại ảnh X-ray lồng ngực để phát hiện bệnh viêm phổi. Thông qua đề tài, người thực hiện hướng tới việc hiểu sâu bản chất của các thuật toán học sâu thay vì chỉ sử dụng các thư viện có sẵn.

Cụ thể, đề tài đặt ra các mục tiêu sau:

Hiểu và cài đặt các thành phần cốt lõi của mô hình học sâu: bao gồm mạng nơ-ron nhiều lớp (Multi-Layer Perceptron), các hàm kích hoạt, hàm mất mát, quá trình lan truyền xuôi (forward propagation) và lan truyền ngược (backpropagation).

Xây dựng mô hình học sâu nhiều lớp (5 layer) bằng Python từ đầu, không sử dụng các thư viện học sâu như TensorFlow, PyTorch hay các framework tương tự, nhằm đảm bảo tuân thủ yêu cầu của môn học và nâng cao khả năng làm chủ thuật toán.

Áp dụng mô hình đề xuất cho bài toán phân loại ảnh X-ray viêm phổi, thông qua việc tiền xử lý dữ liệu ảnh và biểu diễn ảnh dưới dạng vector số phù hợp với mô hình học sâu được xây dựng.

Huấn luyện và đánh giá hiệu quả của mô hình trên tập dữ liệu ảnh X-ray, sử dụng các tiêu chí đánh giá phổ biến như độ chính xác (Accuracy), Precision, Recall và F1-score để phân tích khả năng phân loại của mô hình.

Phân tích ưu điểm và hạn chế của phương pháp xây dựng mô hình từ đầu, đặc biệt trong bối cảnh dữ liệu ảnh có độ phức tạp cao và các ràng buộc về tài nguyên tính toán.

Thông qua các mục tiêu trên, đề tài không chỉ nhằm đạt được kết quả phân loại hợp lý trên dữ liệu ảnh X-ray, mà quan trọng hơn là *củng cố nền tảng lý thuyết và kỹ năng thực hành học sâu*, tạo tiền đề cho việc phát triển các mô hình phức tạp hơn cũng như các ứng dụng học sâu thời gian thực trong giai đoạn tiếp theo của học phần.

1.3. Các đóng góp của bài báo cáo

Bài báo cáo này tập trung vào việc *củng cố và minh họa các kiến thức nền tảng của học sâu* thông qua việc xây dựng và huấn luyện một mô hình học sâu từ đầu. Các đóng góp chính của bài báo cáo có thể được tóm tắt như sau:

Cài đặt hoàn chỉnh một mô hình học sâu nhiều lớp (5 layer) từ đầu, bao gồm toàn bộ quá trình lan truyền xuôi, lan truyền ngược, tính toán hàm mất mát và cập nhật tham số, không sử dụng các thư viện học sâu có sẵn. Điều này giúp làm rõ cơ chế hoạt động bên trong của các mô hình học sâu cơ bản.

Xây dựng quy trình tiền xử lý và biểu diễn dữ liệu ảnh X-ray phù hợp với mô hình học sâu được cài đặt từ đầu, góp phần làm rõ mối liên hệ giữa dữ liệu đầu vào và cấu trúc mô hình trong bài toán phân loại ảnh y tế.

Thực hiện đánh giá thực nghiệm chi tiết trên tập dữ liệu ảnh X-ray viêm phổi, sử dụng các chỉ số đánh giá phổ biến như Accuracy, Precision, Recall và F1-score, từ đó phân tích khả năng phân loại cũng như các hạn chế của mô hình.

Phân tích tác động của các yếu tố mô hình và dữ liệu, bao gồm số lượng lớp, kích thước ảnh đầu vào và các siêu tham số huấn luyện, nhằm làm rõ những đánh đổi giữa độ chính xác và chi phí tính toán khi xây dựng mô hình học sâu từ đầu.

Cung cấp nền tảng cho việc mở rộng và phát triển trong giai đoạn tiếp theo, đặc biệt là hướng tới các mô hình học sâu phức tạp hơn và các ứng dụng thời gian thực trong đồ án cuối kỳ.

Các đóng góp của bài báo cáo mang tính *học thuật và thực hành*, phù hợp với mục tiêu của học phần Fundamental of Deep Learning, đồng thời giúp người thực hiện nâng cao khả năng tự xây dựng và đánh giá mô hình học sâu trong các bài toán thực tế.

II. Phát biểu bài toán

2.1. Mô tả bài toán

Bài toán được xem xét trong báo cáo này là *bài toán phân loại ảnh X-ray lồng ngực nhằm phát hiện bệnh viêm phổi (Pneumonia)*. Đây là một bài toán phân loại có giám sát (supervised learning), trong đó mục tiêu là xây dựng một mô hình học sâu có khả năng dự đoán tình trạng bệnh của bệnh nhân dựa trên ảnh X-ray đầu vào.

Cụ thể, đầu vào của bài toán là *ảnh X-ray lồng ngực* của bệnh nhân, được thu thập trong điều kiện chụp khác nhau và có sự đa dạng về chất lượng, độ phân giải cũng như đặc điểm hình

ảnh. Mỗi ảnh được gán một *nhãn thực* (*ground-truth label*) tương ứng với tình trạng lâm sàng, bao gồm hai lớp chính: *Normal* (bình thường) và *Pneumonia* (viêm phổi).

Nhiệm vụ của mô hình học sâu là học một hàm ánh xạ từ không gian ảnh đầu vào sang không gian nhãn đầu ra, sao cho với mỗi ảnh X-ray mới, mô hình có thể *tự động dự đoán chính xác* ảnh đó thuộc lớp bình thường hay lớp viêm phổi. Về mặt hình thức, đây là *bài toán phân loại nhị phân*, trong đó đầu ra của mô hình biểu diễn xác suất ảnh thuộc mỗi lớp.

Do mô hình được xây dựng từ đầu và không sử dụng các thư viện học sâu có sẵn, ảnh X-ray đầu vào được *tiền xử lý và biểu diễn dưới dạng vector số* trước khi đưa vào mô hình. Quá trình này bao gồm việc chuyển ảnh về dạng xám, thay đổi kích thước và chuẩn hóa giá trị pixel, nhằm đảm bảo dữ liệu đầu vào phù hợp với kiến trúc mạng nơ-ron nhiều lớp được đề xuất.

Bài toán phân loại ảnh X-ray viêm phổi đặt ra nhiều thách thức, không chỉ do đặc tính phức tạp của dữ liệu ảnh y tế mà còn do các ràng buộc trong việc cài đặt mô hình từ đầu. Tuy nhiên, việc giải quyết bài toán này mang lại giá trị thực tiễn cao, đồng thời tạo điều kiện để phân tích sâu cơ chế hoạt động của các mô hình học sâu cơ bản trong một kịch bản ứng dụng cụ thể.

2.2. Biểu diễn toán học

Bài toán phân loại ảnh X-ray viêm phổi được biểu diễn dưới dạng một bài toán học có giám sát, trong đó tập dữ liệu huấn luyện được ký hiệu là

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N,$$

với x_i là biểu diễn số của ảnh X-ray thứ i và y_i là nhãn tương ứng.

Sau bước tiền xử lý, mỗi ảnh X-ray được chuyển thành một *vector đặc trưng*

$$x_i \in \mathbb{R}^d,$$

trong đó d là số chiều của vector, phụ thuộc vào kích thước ảnh đầu vào sau khi được thay đổi kích thước và làm phẳng (flatten). Giá trị của mỗi phần tử trong vector được chuẩn hóa về khoảng $[0,1]$ nhằm ổn định quá trình huấn luyện.

Mô hình học sâu được xây dựng trong báo cáo này là một *mạng nơ-ron nhiều lớp* (*Multi-Layer Perceptron – MLP*) gồm $L=5$ lớp có tham số học, trong đó bốn lớp đầu là các lớp ẩn (hidden layers) và lớp cuối là lớp đầu ra. Mỗi lớp trong mạng thực hiện một phép biến đổi tuyến tính kết hợp với một hàm kích hoạt phi tuyến. Cụ thể, với lớp thứ III, phép biến đổi được mô tả như sau:

$$z^{(l)} = W^{(l)}a^{(l-1)} + b^{(l)},$$

$$a^{(l)} = \phi\left(z^{(l)}\right),$$

trong đó $W^{(l)}$ và $b^{(l)}$ lần lượt là ma trận trọng số và vector độ lệch (bias) của lớp thứ l , $a^{(l-1)}$ là đầu ra của lớp trước đó, và $\phi(\cdot)$ là hàm kích hoạt.

Trong các lớp ẩn, hàm kích hoạt *ReLU (Rectified Linear Unit)* được sử dụng nhằm tăng tính phi tuyến của mô hình và giảm hiện tượng mất gradient. Đối với lớp đầu ra, mô hình sử dụng hàm *Softmax* để ánh xạ đầu ra của mạng thành phân phối xác suất trên hai lớp Normal và Pneumonia.

Đầu ra cuối cùng của mô hình có thể được xem như một hàm ánh xạ:

$$\hat{y}_i = f(x_i; \theta),$$

trong đó $\theta = \{W^{(l)}, b^{(l)}\}_{l=1}^L$ là tập các tham số của mô hình. Quá trình huấn luyện mô hình được thực hiện bằng cách tối ưu hóa hàm mất mát *Cross-Entropy*, được định nghĩa như sau:

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_{i=1}^N y_i \log(\hat{y}_i),$$

nhằm làm giảm sự khác biệt giữa nhãn dự đoán và nhãn thực.

Việc tối ưu hàm mất mát được thực hiện thông qua thuật toán *Gradient Descent*, trong đó các tham số của mô hình được cập nhật ngược chiều gradient của hàm mất mát. Toàn bộ quá trình lan truyền xuôi, lan truyền ngược và cập nhật tham số đều được cài đặt từ đầu bằng Python, không sử dụng các thư viện học sâu có sẵn.

2.3. Thách thức của bài toán

Bài toán phân loại ảnh X-ray viêm phổi đặt ra nhiều thách thức cả về *dữ liệu lẫn phương pháp xây dựng mô hình*, đặc biệt trong bối cảnh mô hình học sâu được cài đặt từ đầu mà không sử dụng các thư viện học sâu có sẵn.

Thứ nhất, *đặc tính của dữ liệu ảnh X-ray y tế* là một thách thức lớn. Ảnh X-ray thường có độ tương phản thấp, nhiễu cao và sự khác biệt giữa các lớp Normal và Pneumonia không luôn thể hiện rõ ràng về mặt trực quan. Nhiều trường hợp viêm phổi chỉ biểu hiện bằng các thay đổi mờ nhạt trong cấu trúc phổi, khiến việc phân biệt bằng các phương pháp tự động trở nên khó khăn.

Thứ hai, *sự mất cân bằng dữ liệu* giữa các lớp là vấn đề phổ biến trong các tập dữ liệu y tế. Trong dữ liệu ảnh X-ray viêm phổi, số lượng ảnh thuộc lớp Pneumonia thường lớn hơn đáng kể so với lớp Normal, dẫn đến nguy cơ mô hình bị thiên lệch trong quá trình huấn luyện nếu không có chiến lược xử lý phù hợp.

Thứ ba, *việc cài đặt mô hình học sâu từ đầu (from scratch)* tạo ra các ràng buộc đáng kể về mặt tính toán và triển khai. Không sử dụng các thư viện học sâu đồng nghĩa với việc toàn bộ quá trình lan truyền xuôi, lan truyền ngược và cập nhật tham số phải được tự cài đặt thủ công. Điều này làm tăng độ phức tạp của hệ thống, đồng thời hạn chế khả năng sử dụng các kiến trúc sâu hoặc dữ liệu ảnh có độ phân giải cao do chi phí tính toán lớn.

Thứ tư, *việc lựa chọn kiến trúc và siêu tham số* trở nên khó khăn hơn trong bối cảnh triển khai từ đầu. Các quyết định như số lượng lớp ẩn, số lượng nơ-ron trong mỗi lớp, kích thước ảnh đầu vào và tốc độ học (learning rate) đều ảnh hưởng mạnh đến hiệu quả của mô hình, trong khi việc thử nghiệm nhiều cấu hình khác nhau đòi hỏi thời gian và tài nguyên tính toán đáng kể.

Cuối cùng, *khả năng tổng quát hóa của mô hình* cũng là một thách thức quan trọng. Do mô hình được xây dựng dưới dạng mạng nơ-ron nhiều lớp đơn giản, không sử dụng các kiến trúc chuyên biệt cho ảnh như mạng tích chập (CNN), mô hình có thể gặp hạn chế trong việc học các đặc trưng không gian phức tạp của ảnh X-ray, từ đó ảnh hưởng đến độ chính xác khi dự đoán trên dữ liệu chưa từng thấy.

Mặc dù tồn tại nhiều thách thức, việc giải quyết bài toán này mang lại giá trị học tập lớn, giúp người thực hiện hiểu rõ hơn về các giới hạn và đánh đổi trong quá trình xây dựng mô hình học sâu từ đầu, đồng thời tạo nền tảng cho việc mở rộng và cải tiến mô hình trong các giai đoạn tiếp theo của học phần.

III. Nghiên cứu liên quan

3.1. Phương pháp truyền thống

Trước khi các mô hình học sâu trở nên phổ biến, bài toán phân loại ảnh, bao gồm cả *phân loại ảnh X-ray y tế*, chủ yếu được giải quyết bằng các *phương pháp học máy truyền thống* kết hợp với quá trình trích xuất đặc trưng thủ công (handcrafted feature extraction).

Trong các phương pháp này, ảnh đầu vào thường không được đưa trực tiếp vào mô hình học máy mà phải trải qua bước *trích xuất đặc trưng*, nhằm biến đổi ảnh thành một tập các đặc trưng số có ý nghĩa. Các đặc trưng thường được sử dụng bao gồm đặc trưng dựa trên cường độ pixel, histogram mức xám, các đặc trưng kết cấu (texture) như GLCM, hoặc các đặc trưng hình học được thiết kế dựa trên kinh nghiệm của chuyên gia.

Sau khi trích xuất đặc trưng, các thuật toán học máy truyền thống như *k-Nearest Neighbors (KNN)*, *Support Vector Machine (SVM)*, *Logistic Regression* hoặc *Naive Bayes* được áp dụng để thực hiện phân loại. Những phương pháp này có ưu điểm là *dễ triển khai, chi phí tính toán thấp* và *phù hợp với tập dữ liệu nhỏ*, do đó đã được sử dụng rộng rãi trong các ứng dụng ban đầu của phân tích ảnh y tế.

Tuy nhiên, các phương pháp truyền thống tồn tại nhiều hạn chế khi áp dụng cho dữ liệu ảnh X-ray. Trước hết, *hiệu quả của mô hình phụ thuộc mạnh vào chất lượng của đặc trưng thủ công*, trong khi việc thiết kế đặc trưng phù hợp đòi hỏi nhiều kinh nghiệm chuyên môn và thường không tổng quát tốt cho các bộ dữ liệu khác nhau. Bên cạnh đó, các đặc trưng thủ công thường khó biểu diễn đầy đủ các mẫu phức tạp và biến thiên lớn trong ảnh X-ray, đặc biệt là các biểu hiện bệnh lý mờ nhạt của viêm phổi.

Ngoài ra, khi kích thước dữ liệu tăng lên hoặc khi bài toán trở nên phức tạp hơn, các phương pháp truyền thống thường *khó mở rộng* và không đạt được hiệu quả cao như mong đợi. Những hạn chế này đã thúc đẩy sự phát triển và ứng dụng rộng rãi của các phương pháp học sâu, cho phép mô hình *tự động học đặc trưng từ dữ liệu thô* mà không cần thiết kế thủ công.

3.2. Phương pháp học sâu hiện đại

Sự phát triển mạnh mẽ của *học sâu (Deep Learning)* đã tạo ra bước đột phá trong các bài toán xử lý ảnh, đặc biệt là trong lĩnh vực *phân tích ảnh y tế*. Không giống như các phương pháp truyền thống dựa trên đặc trưng thủ công, các mô hình học sâu có khả năng *tự động học đặc trưng từ dữ liệu thô*, từ đó nâng cao đáng kể hiệu quả phân loại.

Trong số các mô hình học sâu, *mạng nơ-ron tích chập (Convolutional Neural Network – CNN)* được xem là kiến trúc tiêu biểu và phổ biến nhất cho các bài toán phân loại ảnh. CNN sử dụng các lớp tích chập để khai thác cấu trúc không gian của ảnh, cho phép mô hình học được các đặc trưng cục bộ như cạnh, vùng sáng – tối và các mẫu kết cấu, sau đó kết hợp chúng thành các đặc trưng mức cao hơn. Nhờ đặc tính này, CNN đã đạt được hiệu quả vượt trội trong nhiều ứng dụng thị giác máy tính, bao gồm cả chẩn đoán bệnh từ ảnh X-ray.

Trong lĩnh vực y tế, nhiều nghiên cứu đã áp dụng các kiến trúc CNN hiện đại như VGG, ResNet hay DenseNet để phân loại ảnh X-ray và phát hiện viêm phổi, cho thấy kết quả chính xác cao và khả năng tổng quát tốt. Một số phương pháp còn kết hợp học sâu với kỹ thuật tăng cường dữ liệu (data augmentation) và học chuyển giao (transfer learning) nhằm cải thiện hiệu suất trong bối cảnh dữ liệu y tế thường hạn chế.

Tuy nhiên, việc sử dụng các mô hình học sâu hiện đại thường phụ thuộc nhiều vào *các thư viện và framework chuyên dụng* như TensorFlow hay PyTorch. Mặc dù các công cụ này giúp rút ngắn thời gian triển khai và tối ưu hóa hiệu suất, chúng cũng che giấu phần lớn cơ chế bên trong của quá trình huấn luyện, khiến người học khó nắm bắt đầy đủ bản chất của các thuật toán học sâu, đặc biệt ở mức độ nền tảng.

Bên cạnh đó, các mô hình học sâu phức tạp như CNN sâu đòi hỏi *tài nguyên tính toán lớn* và quá trình tinh chỉnh siêu tham số phức tạp, điều này không luôn phù hợp với mục tiêu học tập trong các học phần cơ sở. Do đó, trong bối cảnh môn Fundamental of Deep Learning, việc tiếp cận học sâu thông qua *các mô hình đơn giản hơn nhưng được cài đặt từ đầu* là một hướng đi hợp lý, giúp người học hiểu rõ nguyên lý hoạt động của học sâu trước khi chuyển sang các kiến trúc phức tạp hơn.

3.3. Nhận xét, hạn chế và định hướng tiếp cận của đề tài

Từ việc khảo sát các phương pháp truyền thống và các phương pháp học sâu hiện đại, có thể nhận thấy rằng mỗi hướng tiếp cận đều có những *ưu điểm và hạn chế riêng* khi áp dụng cho bài toán phân loại ảnh X-ray viêm phổi.

Các phương pháp học máy truyền thống có ưu điểm là *đơn giản, dễ triển khai và chi phí tính toán thấp*, tuy nhiên hiệu quả của chúng phụ thuộc mạnh vào quá trình trích xuất đặc trưng thủ công. Trong bối cảnh dữ liệu ảnh X-ray có tính phức tạp cao và biểu hiện bệnh lý không rõ ràng, các đặc trưng thủ công thường khó có khả năng mô tả đầy đủ các mẫu cần thiết cho việc phân loại chính xác. Do đó, các phương pháp này thường cho kết quả hạn chế khi mở rộng sang các tập dữ liệu lớn hoặc đa dạng.

Ngược lại, các phương pháp học sâu hiện đại, đặc biệt là mạng nơ-ron tích chập, cho thấy *hiệu quả vượt trội* nhờ khả năng tự động học đặc trưng trực tiếp từ dữ liệu thô. Tuy nhiên, việc áp dụng các mô hình này thường gắn liền với sự phụ thuộc vào các thư viện học sâu chuyên dụng và yêu cầu tài nguyên tính toán lớn. Điều này khiến người học khó tiếp cận sâu bản chất của thuật toán, đồng thời không hoàn toàn phù hợp với mục tiêu đào tạo trong học phần Fundamental of Deep Learning, nơi trọng tâm là *hiểu rõ nguyên lý hoạt động của học sâu*.

Xuất phát từ những nhận xét trên, đề tài này lựa chọn *hướng tiếp cận trung gian*, kết hợp giữa tính đơn giản của các mô hình truyền thống và khả năng biểu diễn mạnh mẽ của học sâu. Cụ thể, đề tài tập trung vào việc *xây dựng một mô hình học sâu nhiều lớp (MLP) từ đầu*, không sử dụng các thư viện học sâu có sẵn, nhằm giúp làm rõ cơ chế lan truyền xuôi, lan truyền ngược và quá trình tối ưu tham số.

Mặc dù mô hình được đề xuất không khai thác trực tiếp cấu trúc không gian của ảnh như các mạng CNN hiện đại, việc áp dụng mô hình này cho bài toán phân loại ảnh X-ray vẫn mang lại giá trị học tập lớn. Thông qua việc triển khai từ đầu, người thực hiện có thể *hiểu rõ các đánh đổi giữa độ phức tạp mô hình, chi phí tính toán và hiệu quả phân loại*, cũng như nhận thức được những hạn chế của các kiến trúc đơn giản khi áp dụng cho dữ liệu ảnh.

Định hướng tiếp cận của đề tài không nhằm cạnh tranh với các mô hình học sâu hiện đại về mặt hiệu suất, mà tập trung vào *mục tiêu giáo dục và nền tảng*, tạo tiền đề cho việc mở rộng sang các kiến trúc phức tạp hơn như CNN và các ứng dụng thời gian thực trong giai đoạn tiếp theo của học phần.

IV. Phương pháp đề xuất

4.1. Ý tưởng tổng quát

Xuất phát từ các phân tích ở chương trước, đề tài này lựa chọn hướng tiếp cận *xây dựng một mô hình học sâu nhiều lớp từ đầu (from scratch)* nhằm giải quyết bài toán phân loại ảnh X-ray viêm phổi, với trọng tâm là *hiểu rõ cơ chế hoạt động của học sâu* thay vì tối ưu hiệu suất bằng các kiến trúc phức tạp.

Ý tưởng tổng quát của phương pháp đề xuất là *chuyển đổi bài toán phân loại ảnh thành bài toán học trên vector số*, sau đó áp dụng một *mạng nơ-ron nhiều lớp (Multi-Layer Perceptron – MLP)* để thực hiện phân loại. Cách tiếp cận này cho phép đơn giản hóa việc cài đặt mô hình từ đầu, đồng thời vẫn giữ được bản chất của học sâu thông qua việc sử dụng nhiều lớp ẩn và các hàm kích hoạt phi tuyến.

Cụ thể, quy trình tổng thể của phương pháp bao gồm các bước chính sau:

Tiền xử lý dữ liệu ảnh: Ảnh X-ray đầu vào được chuyển về dạng ảnh xám, thay đổi kích thước về một độ phân giải nhỏ hơn nhằm giảm chi phí tính toán, sau đó được chuẩn hóa và làm phẳng (flatten) để biểu diễn dưới dạng vector số. Bước này giúp đảm bảo dữ liệu đầu vào phù hợp với mô hình MLP và đáp ứng yêu cầu cài đặt từ đầu.

Xây dựng mô hình học sâu nhiều lớp: Mô hình được thiết kế với 5 lớp có tham số học, bao gồm bốn lớp ẩn và một lớp đầu ra. Mỗi lớp thực hiện phép biến đổi tuyến tính kết hợp với hàm kích hoạt phi tuyến ReLU, trong khi lớp đầu ra sử dụng hàm Softmax để sinh ra xác suất dự đoán cho từng lớp.

Huấn luyện mô hình từ đầu: Toàn bộ quá trình lan truyền xuôi, tính toán hàm mất mát và lan truyền ngược được cài đặt thủ công bằng Python, không sử dụng các thư viện học sâu có sẵn. Các tham số của mô hình được cập nhật thông qua thuật toán Gradient Descent, nhằm tối ưu hóa hàm mất mát Cross-Entropy.

Đánh giá và phân tích kết quả: Sau khi huấn luyện, mô hình được đánh giá trên tập dữ liệu kiểm tra thông qua các chỉ số như Accuracy, Precision, Recall và F1-score. Các kết quả thu được được phân tích để làm rõ khả năng phân loại cũng như các hạn chế của phương pháp đề xuất.

Mặc dù phương pháp đề xuất không khai thác trực tiếp cấu trúc không gian của ảnh như các mạng tích chập hiện đại, cách tiếp cận này vẫn phù hợp với mục tiêu của học phần Fundamental of Deep Learning. Việc xây dựng mô hình từ đầu giúp người thực hiện *hiểu sâu các thành phần cốt lõi của học sâu*, đồng thời tạo nền tảng vững chắc cho việc mở rộng sang các kiến trúc phức tạp hơn và các ứng dụng thời gian thực trong giai đoạn tiếp theo.

4.2. Mô hình học sâu 5 lớp xây dựng từ đầu

Trong đề tài này, mô hình được đề xuất là một *mạng nơ-ron nhiều lớp (Multi-Layer Perceptron – MLP)* gồm 5 lớp có tham số học, được cài đặt hoàn toàn từ đầu bằng Python mà không sử dụng các thư viện học sâu có sẵn. Mô hình được thiết kế nhằm đảm bảo tính đơn giản trong triển khai, đồng thời vẫn thể hiện đầy đủ bản chất của học sâu thông qua việc sử dụng nhiều lớp ẩn và các hàm kích hoạt phi tuyến.

1. Cấu trúc tổng thể của mô hình

Mô hình bao gồm:

1 lớp đầu vào (Input layer): nhận vector đặc trưng của ảnh X-ray sau khi tiền xử lý và làm phẳng.

4 lớp ẩn (Hidden layers): thực hiện học các biểu diễn phi tuyến của dữ liệu.

1 lớp đầu ra (Output layer): sinh ra xác suất dự đoán cho mỗi lớp.

Theo cách đếm phổ biến trong học sâu, *chỉ các lớp có tham số học (Dense layers)* được tính vào số lượng layer, do đó mô hình được gọi là *mô hình học sâu 5 lớp*.

2. Biểu diễn toán học của từng lớp

Giả sử vector đầu vào của mô hình là

$$\mathbf{x} \in \mathbb{R}^d,$$

trong đó d là số chiều của vector đặc trưng ảnh X-ray. Với mỗi lớp thứ l trong mạng, phép biến đổi được thực hiện theo hai bước:

$$\begin{aligned} \mathbf{z}^{(l)} &= \mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}, \\ \mathbf{a}^{(l)} &= \phi^{(l)}(\mathbf{z}^{(l)}), \end{aligned}$$

trong đó:

$\mathbf{W}^{(l)}$ là ma trận trọng số của lớp thứ l ,

$\mathbf{b}^{(l)}$ là vector bias,

$\mathbf{a}^{(l-1)}$ là đầu ra của lớp trước đó,

$\phi^{(l)}(.)$ là hàm kích hoạt của lớp thứ l .

3. Các lớp ẩn và hàm kích hoạt

Bốn lớp ẩn của mô hình đều sử dụng **hàm kích hoạt ReLU (Rectified Linear Unit)**, được định nghĩa như sau:

$$\text{ReLU}(x) = \max(0, x).$$

Hàm ReLU được lựa chọn do:

Đơn giản trong cài đặt từ đầu,

Giảm hiện tượng mất gradient,

Giúp mô hình học được các quan hệ phi tuyến hiệu quả hơn.

Số lượng nơ-ron trong các lớp ẩn được giảm dần qua từng lớp, nhằm giúp mô hình *nén dần thông tin* và học các biểu diễn trừu tượng hơn từ dữ liệu ảnh đầu vào.

4. Lớp đầu ra và hàm mất mát

Lớp đầu ra của mô hình gồm *hai nơ-ron*, tương ứng với hai lớp *Normal* và *Pneumonia*. Hàm kích hoạt *Softmax* được sử dụng để chuyển các giá trị đầu ra thành phân phối xác suất:

$$\text{Softmax}(z_i) = \frac{e^{z_i}}{\sum_j e^{z_j}}.$$

Để huấn luyện mô hình, hàm mất mát *Cross-Entropy* được sử dụng nhằm đo lường sự khác biệt giữa nhãn dự đoán và nhãn thực. Hàm mất mát này đặc biệt phù hợp cho các bài toán phân loại nhiều lớp và cho phép kết hợp hiệu quả với hàm Softmax trong quá trình lan truyền ngược.

5. Quá trình huấn luyện từ đầu

Toàn bộ quá trình huấn luyện mô hình được thực hiện thông qua ba bước chính:

Lan truyền xuôi (Forward propagation): tính toán đầu ra của mô hình từ lớp đầu vào đến lớp đầu ra.

Lan truyền ngược (Backpropagation): tính gradient của hàm mất mát đối với các tham số $W^{(l)}$ và $b^{(l)}$ của từng lớp.

Cập nhật tham số: sử dụng thuật toán Gradient Descent để cập nhật trọng số và bias theo hướng làm giảm hàm mất mát.

Tất cả các bước trên đều được cài đặt thủ công bằng Python, giúp làm rõ mối quan hệ giữa lý thuyết học sâu và quá trình triển khai thực tế.

6. Nhận xét

Mô hình học sâu 5 lớp được xây dựng từ đầu trong đề tài này không nhằm mục tiêu đạt hiệu suất tối ưu so với các kiến trúc học sâu hiện đại, mà tập trung vào việc *hiểu rõ cấu trúc và cơ chế hoạt động của mạng nơ-ron nhiều lớp*. Việc triển khai mô hình từ đầu đóng vai trò quan trọng trong việc củng cố nền tảng học sâu và chuẩn bị cho việc tiếp cận các mô hình phức tạp hơn trong các giai đoạn tiếp theo.

4.3. Thuật toán huấn luyện và lan truyền ngược

Quá trình huấn luyện mô hình học sâu 5 lớp trong đề tài này được thực hiện thông qua *thuật toán lan truyền ngược (Backpropagation)* kết hợp với *Gradient Descent*. Toàn bộ thuật toán được cài đặt từ đầu bằng Python, không sử dụng các thư viện học sâu có sẵn, nhằm làm rõ cơ chế tối ưu hóa tham số của mạng nơ-ron nhiều lớp.

1. Lan truyền xuôi (Forward Propagation)

Trong bước lan truyền xuôi, dữ liệu đầu vào được truyền lần lượt qua từng lớp của mạng để tính toán đầu ra cuối cùng. Cụ thể, với một mẫu dữ liệu đầu vào x , mô hình thực hiện các phép biến đổi sau:

Tại mỗi lớp ẩn, mô hình thực hiện phép biến đổi tuyến tính:

$$z^{(l)} = W^{(l)}a^{(l-1)} + b^{(l)},$$

sau đó áp dụng hàm kích hoạt ReLU:

$$a^{(l)} = \max(0, z^{(l)}).$$

Tại lớp đầu ra, mô hình áp dụng hàm Softmax để chuyển các giá trị đầu ra thành xác suất dự đoán:

$$\hat{y} = \text{Softmax}(z^{(L)}).$$

Kết quả của bước lan truyền xuôi là một vector xác suất biểu diễn mức độ tin cậy của mô hình đối với từng lớp (Normal và Pneumonia).

2. Tính toán hàm mất mát

Sau khi thu được đầu ra của mô hình, hàm mất mát *Cross-Entropy* được sử dụng để đo lường sự sai khác giữa nhãn dự đoán $\hat{y}$ và nhãn thực y . Với một mẫu dữ liệu, hàm mất mát được định nghĩa như sau:

$$\mathcal{L} = - \sum_{k=1}^C y_k \log(\hat{y}_k),$$

trong đó C là số lớp và y_k là vector nhãn dạng one-hot. Hàm mất mát này cho phép đánh giá trực tiếp mức độ chính xác của mô hình trong bài toán phân loại.

3. Lan truyền ngược (Backpropagation)

Lan truyền ngược là bước quan trọng nhất trong quá trình huấn luyện, nhằm tính gradient của hàm mất mát đối với các tham số của mô hình. Quá trình này được thực hiện theo thứ tự ngược lại so với lan truyền xuôi, bắt đầu từ lớp đầu ra và kết thúc tại lớp đầu vào.

Tại lớp đầu ra, gradient của hàm mất mát đối với đầu vào của lớp Softmax có thể được tính gọn như:

$$\frac{\partial \mathcal{L}}{\partial z^{(L)}} = \hat{y} - y.$$

Tại các lớp ẩn, gradient được lan truyền ngược thông qua đạo hàm của hàm kích hoạt ReLU:

$$\frac{\partial \mathcal{L}}{\partial z^{(l)}} = \frac{\partial \mathcal{L}}{\partial a^{(l)}} \cdot \mathbf{1}_{z^{(l)} > 0},$$

trong đó $\mathbf{1}_{z^{(l)} > 0}$ là hàm chỉ báo của ReLU.

Gradient đối với các tham số $W^{(l)}$ và $b^{(l)}$ được tính như:

$$\frac{\partial \mathcal{L}}{\partial W^{(l)}} = \frac{\partial \mathcal{L}}{\partial z^{(l)}} \cdot (a^{(l-1)})^T,$$

$$\frac{\partial \mathcal{L}}{\partial b^{(l)}} = \frac{\partial \mathcal{L}}{\partial z^{(l)}}.$$

Toàn bộ các phép tính gradient này được cài đặt thủ công trong mã nguồn, giúp làm rõ cách mà sai số được lan truyền ngược qua từng lớp của mạng nơ-ron.

4. Cập nhật tham số và chiến lược huấn luyện

Sau khi tính toán gradient, các tham số của mô hình được cập nhật bằng *thuật toán Gradient Descent* theo công thức:

$$W^{(l)} \leftarrow W^{(l)} - \eta \frac{\partial \mathcal{L}}{\partial W^{(l)}}, \quad b^{(l)} \leftarrow b^{(l)} - \eta \frac{\partial \mathcal{L}}{\partial b^{(l)}},$$

trong đó η là tốc độ học (learning rate). Trong đề tài này, mô hình được huấn luyện theo *mini-batch*, giúp cân bằng giữa tốc độ hội tụ và độ ổn định của quá trình học.

Quá trình huấn luyện được lặp lại qua nhiều epoch cho đến khi hàm mất mát hội tụ hoặc đạt số vòng lặp định trước. Trong mỗi epoch, mô hình được đánh giá trên tập dữ liệu kiểm tra nhằm theo dõi khả năng tổng quát hóa.

5. Nhận xét

Thuật toán huấn luyện và lan truyền ngược được cài đặt từ đầu trong đề tài này cho phép người thực hiện *hiểu rõ mối quan hệ giữa lý thuyết và thực hành trong học sâu*. Việc tự triển khai backpropagation giúp làm rõ cách mà sai số ảnh hưởng đến từng tham số của mô hình, đồng thời minh họa rõ ràng vai trò của các thành phần như hàm kích hoạt, hàm mất mát và thuật toán tối ưu trong quá trình huấn luyện mạng nơ-ron nhiều lớp.

4.4. Phân tích độ phức tạp

Trong mục này, độ phức tạp của mô hình học sâu 5 lớp được phân tích nhằm làm rõ *chi phí tính toán và những ràng buộc thực tế* khi cài đặt mô hình từ đầu mà không sử dụng các thư viện học sâu chuyên dụng.

1. Độ phức tạp theo kích thước dữ liệu và mô hình

Giả sử:

d là số chiều của vector đầu vào (phụ thuộc vào kích thước ảnh sau khi tiền xử lý),

n_l là số nơ-ron của lớp thứ l ,

L là số lớp có tham số học (trong đề tài này, $L=5$),

N là số mẫu trong tập huấn luyện.

Trong mỗi lớp fully-connected, phép biến đổi tuyến tính yêu cầu:

$$\mathcal{O}(n_{l-1} \times n_l)$$

phép toán nhân – cộng cho mỗi mẫu dữ liệu. Do đó, *độ phức tạp của một lần lan truyền xuôi* qua toàn bộ mô hình xấp xỉ:

$$\mathcal{O} \left(\sum_{l=1}^L n_{l-1} \times n_l \right).$$

Quá trình *lan truyền ngược* có độ phức tạp cùng bậc với lan truyền xuôi, do đó *chi phí huấn luyện cho một mẫu dữ liệu* xấp xỉ gấp đôi chi phí của forward propagation.

2. Độ phức tạp theo số epoch và mini-batch

Khi huấn luyện mô hình theo chiến lược mini-batch với kích thước batch là BBB , số phép tính trong một epoch tỷ lệ với:

$$\mathcal{O} \left(E \times N \times \sum_{l=1}^L n_{l-1} \times n_l \right).$$

Tổng chi phí huấn luyện của mô hình sau EEE epoch được xấp xỉ:

$$\mathcal{O} \left(E \times N \times \sum_{l=1}^L n_{l-1} \times n_l \right).$$

Điều này cho thấy chi phí tính toán *tăng tuyến tính theo số mẫu dữ liệu và số epoch*, nhưng *tăng nhanh theo kích thước của các lớp trong mô hình*.

3. Ảnh hưởng của kích thước ảnh đầu vào

Trong mô hình đề xuất, ảnh X-ray được chuyển thành vector đầu vào bằng cách làm phẳng ảnh sau khi thay đổi kích thước. Do đó, số chiều của vector đầu vào *tăng theo bình phương kích thước ảnh*. Ví dụ, khi tăng kích thước ảnh từ 32×32 lên 64×64 , số chiều đầu vào tăng gấp bốn lần, kéo theo chi phí tính toán của lớp đầu tiên tăng tương ứng.

Trong bối cảnh cài đặt mô hình từ đầu, việc sử dụng ảnh có độ phân giải thấp hơn là một *đánh đổi hợp lý* nhằm giảm chi phí tính toán, đảm bảo mô hình có thể huấn luyện trong thời gian chấp nhận được mà vẫn giữ được các đặc trưng tổng quát cần thiết cho bài toán phân loại.

4. Nhận xét


Phân tích độ phức tạp cho thấy mô hình học sâu 5 lớp được xây dựng từ đầu có *chi phí tính toán đáng kể*, đặc biệt khi kích thước ảnh đầu vào và số lượng nơ-ron tăng lên. Tuy nhiên, trong phạm vi mục tiêu của học phần Fundamental of Deep Learning, mô hình đề xuất vẫn đảm bảo *tính khả thi về mặt tính toán*, đồng thời cung cấp môi trường phù hợp để người học hiểu rõ mối quan hệ giữa kiến trúc mô hình, dữ liệu đầu vào và chi phí huấn luyện.

Việc phân tích này cũng làm rõ lý do vì sao các thư viện học sâu hiện đại và các kiến trúc chuyên biệt như CNN đóng vai trò quan trọng trong các ứng dụng thực tế, từ đó tạo động lực cho việc mở rộng và cải tiến mô hình trong các giai đoạn tiếp theo của học phần.

4.5. Hình minh họa mô hình

Để làm rõ cấu trúc và quy trình hoạt động của phương pháp đề xuất, trong mục này trình bày các *hình minh họa trực quan* cho mô hình học sâu 5 lớp cũng như pipeline xử lý dữ liệu. Các hình minh họa này giúp người đọc dễ dàng nắm bắt mối quan hệ giữa dữ liệu đầu vào, kiến trúc mô hình và kết quả đầu ra.

1. Sơ đồ kiến trúc mô hình học sâu 5 lớp



Hình minh họa kiến trúc mô hình thể hiện cấu trúc tổng thể của mạng nơ-ron nhiều lớp được xây dựng từ đầu. Mô hình bao gồm:


Một lớp đầu vào nhận vector đặc trưng của ảnh X-ray sau khi tiền xử lý,

Bốn lớp ẩn fully-connected sử dụng hàm kích hoạt ReLU,

Một lớp đầu ra sử dụng hàm Softmax để dự đoán xác suất của các lớp Normal và Pneumonia.

Sơ đồ kiến trúc cho thấy luồng dữ liệu được truyền tuần tự từ lớp đầu vào đến lớp đầu ra thông qua các phép biến đổi tuyến tính và phi tuyến. Việc giảm dần số lượng nơ-ron qua các lớp ẩn giúp mô hình nén thông tin và học các biểu diễn trừu tượng hơn từ dữ liệu đầu vào.

2. Pipeline xử lý dữ liệu và huấn luyện



Bên cạnh sơ đồ kiến trúc, pipeline xử lý dữ liệu và huấn luyện mô hình cũng được minh họa nhằm làm rõ các bước chính trong phương pháp đề xuất. Pipeline bao gồm các giai đoạn:

Thu thập và tiền xử lý dữ liệu ảnh: đọc ảnh X-ray, chuyển ảnh sang dạng xám, thay đổi kích thước và chuẩn hóa.

Biểu diễn dữ liệu: làm phẳng ảnh thành vector số và gán nhãn tương ứng.

Huấn luyện mô hình học sâu từ đầu: thực hiện lan truyền xuôi, tính hàm mất mát, lan truyền ngược và cập nhật tham số.

Đánh giá và dự đoán: đánh giá mô hình trên tập kiểm tra và sử dụng mô hình đã huấn luyện để dự đoán các mẫu mới.

Pipeline này giúp làm rõ sự liên kết giữa các bước tiền xử lý dữ liệu và quá trình huấn luyện mô hình, đồng thời minh họa cách mà mô hình được áp dụng trong bài toán phân loại ảnh X-ray viêm phổi.

3. Vai trò của hình minh họa trong báo cáo

Các hình minh họa không chỉ giúp tăng tính trực quan của báo cáo mà còn hỗ trợ việc *giải thích mô hình và thuật toán* một cách rõ ràng hơn. Đặc biệt trong bối cảnh mô hình được xây dựng từ đầu, việc sử dụng hình minh họa giúp người đọc dễ dàng hiểu được cấu trúc mạng và quy trình huấn luyện mà không cần đi sâu ngay vào chi tiết mã nguồn.

V. Kết quả thực nghiệm

5.1. Cấu hình thực nghiệm

Trong mục này, các thiết lập và điều kiện thực nghiệm được trình bày nhằm đảm bảo tính minh bạch và khả năng tái lập (reproducibility) của kết quả thu được. Toàn bộ quá trình huấn luyện và đánh giá mô hình được thực hiện theo đúng yêu cầu của học phần Fundamental of Deep Learning, với mô hình học sâu được cài đặt từ đầu mà không sử dụng các thư viện học sâu chuyên dụng.

1. Môi trường thực nghiệm

Các thí nghiệm được thực hiện trên môi trường lập trình Python. Mô hình học sâu được cài đặt hoàn toàn từ đầu bằng Python thuần cho phần huấn luyện và suy luận. Các thư viện bên ngoài (nếu có) chỉ được sử dụng cho mục đích *đọc và tiền xử lý dữ liệu ảnh*, không tham gia vào quá trình xây dựng hay huấn luyện mô hình học sâu.

Thực nghiệm được triển khai trong môi trường máy tính cá nhân/Google Colab, đảm bảo đủ tài nguyên để huấn luyện mô hình với dữ liệu ảnh đã được giảm kích thước phù hợp.

2. Thiết lập dữ liệu đầu vào

Ảnh X-ray lồng ngực được chuyển về dạng ảnh xám và thay đổi kích thước trước khi đưa vào mô hình. Sau đó, ảnh được chuẩn hóa giá trị pixel về khoảng $[0,1][0,1][0,1]$ và làm phẳng (flatten) để biểu diễn dưới dạng vector số.

Cấu hình dữ liệu đầu vào được thiết lập như sau:

Kích thước ảnh sau tiền xử lý: 32×32

Số chiều vector đầu vào: 1024

Số lớp phân loại: 2 (Normal, Pneumonia)

Việc lựa chọn kích thước ảnh nhỏ nhằm giảm chi phí tính toán, phù hợp với việc cài đặt mô hình học sâu từ đầu.

3. Cấu hình mô hình và huấn luyện

Mô hình học sâu được sử dụng trong thực nghiệm là mạng nơ-ron nhiều lớp gồm 5 lớp có tham số học, trong đó bao gồm bốn lớp ẩn và một lớp đầu ra. Các lớp ẩn sử dụng hàm kích hoạt ReLU, trong khi lớp đầu ra sử dụng hàm Softmax.

Quá trình huấn luyện được thực hiện với các siêu tham số sau:

Thuật toán tối ưu: Gradient Descent

Hàm mất mát: Cross-Entropy

Tốc độ học (Learning rate): được lựa chọn thông qua thử nghiệm để đảm bảo quá trình hội tụ ổn định

Chiến lược huấn luyện: Mini-batch

Số epoch huấn luyện: cố định trong các thí nghiệm để đảm bảo so sánh công bằng giữa các mô hình

Trong mỗi epoch, mô hình được huấn luyện trên tập dữ liệu huấn luyện và sau đó được đánh giá trên tập dữ liệu kiểm tra nhằm theo dõi hiệu suất và khả năng tổng quát hóa.

4. Quy trình thực nghiệm

Quy trình thực nghiệm được thực hiện theo các bước sau:

Tiền xử lý và chuẩn bị dữ liệu ảnh X-ray.

Khởi tạo mô hình học sâu 5 lớp với các tham số ngẫu nhiên.

Huấn luyện mô hình từ đầu thông qua lan truyền xuôi và lan truyền ngược.

Đánh giá mô hình trên tập dữ liệu kiểm tra.

Lưu trọng số mô hình và sử dụng để thực hiện các thí nghiệm đánh giá và demo.

Quy trình trên đảm bảo toàn bộ các kết quả thực nghiệm phản ánh đúng hiệu quả của mô hình học sâu được xây dựng từ đầu, đồng thời phù hợp với mục tiêu học tập của học phần.

5.2. Baseline so sánh

Trong các bài toán học sâu, việc so sánh mô hình đề xuất với các baseline phù hợp là cần thiết nhằm đánh giá hiệu quả của phương pháp. Tuy nhiên, trong phạm vi của học phần *Fundamental of Deep Learning* và với yêu cầu *cài đặt mô hình từ đầu (from scratch)*, việc so sánh với các mô hình học sâu hiện đại sử dụng thư viện chuyên dụng như CNN không được xem là phù hợp.

Do đó, trong đề tài này, các baseline được lựa chọn dựa trên *những biến thể đơn giản hơn của chính mô hình đề xuất*, nhằm làm rõ tác động của kiến trúc mạng và các thành phần huấn luyện đến hiệu quả phân loại.

Cụ thể, các baseline được sử dụng bao gồm:

Baseline 1 – MLP nông (ít lớp):

Mô hình mạng nơ-ron nhiều lớp với số lượng lớp ẩn ít hơn (ví dụ 2–3 lớp), được cài đặt từ đầu với cùng phương pháp huấn luyện. Baseline này nhằm đánh giá vai trò của độ sâu mô hình đối với khả năng học đặc trưng từ dữ liệu ảnh X-ray.

Baseline 2 – Không chuẩn hóa dữ liệu đầu vào:

Mô hình MLP 5 lớp tương tự mô hình đề xuất nhưng không thực hiện bước chuẩn hóa giá trị pixel. Baseline này giúp đánh giá ảnh hưởng của bước tiền xử lý dữ liệu đối với độ ổn định và hiệu quả huấn luyện.

Baseline 3 – Thay đổi kích thước ảnh đầu vào:

Mô hình được huấn luyện với các kích thước ảnh đầu vào khác nhau (ví dụ 32×32 so với 64×64), nhằm phân tích sự đánh đổi giữa độ chi tiết của dữ liệu đầu vào và chi phí tính toán trong bối cảnh cài đặt từ đầu.

Các baseline trên được lựa chọn nhằm đảm bảo:

Tuân thủ yêu cầu không sử dụng thư viện học sâu,

Cho phép so sánh công bằng trong cùng một khung cài đặt,

Làm rõ vai trò của từng thành phần trong mô hình học sâu từ đầu.

Thông qua việc so sánh mô hình đề xuất với các baseline này, bài báo cáo hướng tới việc phân tích sâu hơn *ảnh hưởng của kiến trúc mạng và chiến lược tiền xử lý* đến hiệu quả phân loại ảnh X-ray viêm phổi, thay vì chỉ tập trung vào việc đạt độ chính xác cao nhất.

5.3. Dữ liệu sử dụng

Trong thực nghiệm của đề tài, tập dữ liệu chính được sử dụng là “*Chest X-Ray Images (Pneumonia)*”, thu thập từ *Kaggle* và được cung cấp bởi Paul Mooney. Đây là một trong những bộ dữ liệu chuẩn và được sử dụng rộng rãi trong các nghiên cứu và bài tập về phân loại ảnh y tế liên quan đến chẩn đoán viêm phổi.

Nguồn dữ liệu:

<https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia>

1. Tổng quan về dataset

Bộ dữ liệu Chest X-Ray Pneumonia gồm:

Ảnh X-ray lồng ngực ở định dạng *JPEG/PNG*

Nhãn gắn theo *hai lớp*:

NORMAL: ảnh phổi bình thường

PNEUMONIA: ảnh phổi có biểu hiện viêm phổi

Dữ liệu được phân chia sẵn theo cấu trúc thư mục, hỗ trợ việc đọc và xử lý trực tiếp:

train/

```
├─ NORMAL/
└─ PNEUMONIA/
```

val/

```
├─ NORMAL/
└─ PNEUMONIA/
```

test/

```
├─ NORMAL/
└─ PNEUMONIA/
```

Mỗi tập con (train, val, test) được tổ chức theo cấu trúc trên nhằm đảm bảo việc tách biệt giữa dữ liệu huấn luyện, kiểm định và đánh giá cuối cùng.

2. Quy mô dữ liệu

Dataset có số lượng ảnh tương đối lớn và phân bố không hoàn toàn cân bằng giữa hai lớp:

Tập dữ liệu NORMAL PNEUMONIA

Train	~1,341	~3,800
Val	8	8
Test	~234	~390

Con số trên là dựa theo cấu trúc gốc của dataset và có thể thay đổi nếu bạn chọn giới hạn số ảnh trong code để giảm thời gian train.

3. Đặc trưng của dữ liệu

Định dạng ảnh: JPG/PNG, kích thước đa dạng

Độ phân giải: khác nhau tùy ảnh (từ nhỏ đến lớn)

Màu sắc: ảnh y tế thường ở dạng grayscale

Nhãn: 2 lớp rõ ràng

Dữ liệu mất cân bằng: số ảnh PNEUMONIA nhiều hơn NORMAL

Mỗi ảnh sau khi đọc được tiền xử lý gồm:

Chuyển sang ảnh xám (grayscale)

Resize về kích thước chuẩn như trong phần 5.1

Chuẩn hóa và flatten thành vector số

4. Lý do lựa chọn dataset

Dataset này được lựa chọn vì:

Phổ biến trong nghiên cứu DL y tế, nhiều tài liệu tham khảo;


Dữ liệu đã tách train/val/test sẵn, thuận tiện cho thí nghiệm;

Phù hợp với bài toán phân loại nhị phân;

Phù hợp yêu cầu code model từ đầu, vì kích thước và cấu trúc dữ liệu đủ lớn nhưng không quá nặng nếu resize.

5. Sơ đồ cấu trúc dữ liệu

X-ray:



5.4. Tiêu chí đánh giá

Để đánh giá hiệu quả của mô hình học sâu được xây dựng từ đầu trong bài toán phân loại ảnh X-ray viêm phổi, đề tài sử dụng các *tiêu chí đánh giá phổ biến trong các bài toán phân loại nhị phân*, đặc biệt phù hợp với dữ liệu y tế.

Các tiêu chí đánh giá được lựa chọn không chỉ phản ánh độ chính xác tổng thể của mô hình mà còn giúp phân tích chi tiết khả năng dự đoán đúng từng lớp, đặc biệt trong bối cảnh dữ liệu có sự mất cân bằng giữa các lớp.

1. Ma trận nhầm lẫn (Confusion Matrix)

Ma trận nhầm lẫn được sử dụng để tổng hợp kết quả dự đoán của mô hình so với nhãn thực tế. Đối với bài toán phân loại nhị phân (Normal và Pneumonia), ma trận nhầm lẫn bao gồm bốn trường hợp:

True Positive (TP): ảnh viêm phổi được dự đoán đúng là viêm phổi

True Negative (TN): ảnh bình thường được dự đoán đúng là bình thường

False Positive (FP): ảnh bình thường nhưng bị dự đoán nhầm là viêm phổi

False Negative (FN): ảnh viêm phổi nhưng bị dự đoán nhầm là bình thường

Ma trận nhầm lẫn cung cấp cái nhìn trực quan về các loại lỗi mà mô hình mắc phải, đặc biệt quan trọng trong các ứng dụng y tế.

2. Độ chính xác (Accuracy)

Độ chính xác (Accuracy) đo lường tỷ lệ mẫu được dự đoán đúng trên tổng số mẫu kiểm tra, được định nghĩa như sau:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Chỉ số này phản ánh hiệu quả tổng thể của mô hình. Tuy nhiên, trong trường hợp dữ liệu mất cân bằng, Accuracy có thể chưa phản ánh đầy đủ khả năng phân loại của mô hình đối với từng lớp.

3. Precision

Precision đo lường mức độ chính xác của các dự đoán dương tính (Pneumonia), được định nghĩa như sau:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Chỉ số này cho biết trong số các ảnh được mô hình dự đoán là viêm phổi, có bao nhiêu ảnh thực sự là viêm phổi. Precision cao giúp hạn chế các trường hợp *chẩn đoán nhầm bệnh*.

4. Recall

Recall (hay Sensitivity) đo lường khả năng mô hình phát hiện đúng các trường hợp viêm phổi, được định nghĩa như sau:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Trong bối cảnh bài toán y tế, Recall là chỉ số đặc biệt quan trọng vì nó phản ánh khả năng *phát hiện bệnh*, giúp hạn chế các trường hợp bỏ sót bệnh nhân mắc viêm phổi.

5. F1-score

F1-score là trung bình điều hòa giữa Precision và Recall, được sử dụng để cân bằng giữa hai tiêu chí này:

$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

F1-score cho phép đánh giá tổng quát hiệu quả phân loại của mô hình trong trường hợp dữ liệu không cân bằng, đồng thời phản ánh mức độ ổn định của mô hình.

6. Nhận xét

Việc sử dụng kết hợp nhiều tiêu chí đánh giá giúp đánh giá toàn diện hiệu quả của mô hình học sâu được xây dựng từ đầu. Trong bài toán phân loại ảnh X-ray viêm phổi, các chỉ số như Recall và F1-score đóng vai trò quan trọng không kém Accuracy, do ảnh hưởng trực tiếp đến khả năng phát hiện bệnh trong các ứng dụng y tế thực tế.

5.5. Phân tích kết quả thực nghiệm

Dựa trên các thí nghiệm đã thực hiện, mô hình học sâu 5 lớp được xây dựng từ đầu cho thấy *khả năng phân loại tương đối tốt* trên tập dữ liệu ảnh X-ray viêm phổi, mặc dù kiến trúc mô hình đơn giản và không sử dụng các mạng chuyên biệt cho xử lý ảnh như CNN.

1. Đánh giá tổng thể hiệu năng mô hình

Kết quả thực nghiệm cho thấy mô hình đạt được *độ chính xác (Accuracy) ổn định* trên tập kiểm tra. Điều này cho thấy mạng nơ-ron nhiều lớp vẫn có khả năng học được các đặc trưng tổng quát từ dữ liệu ảnh X-ray sau khi được tiền xử lý và vector hóa, ngay cả khi ảnh đầu vào có độ phân giải thấp.

Tuy Accuracy là chỉ số tổng quát, việc phân tích sâu hơn thông qua các chỉ số Precision, Recall và F1-score cho thấy mô hình có xu hướng *phát hiện khá tốt các trường hợp viêm phổi*, điều này đặc biệt quan trọng trong bối cảnh ứng dụng y tế.

2. Phân tích ma trận nhầm lẫn

Ma trận nhầm lẫn cho thấy số lượng dự đoán đúng ở cả hai lớp Normal và Pneumonia chiếm tỷ lệ lớn so với tổng số mẫu kiểm tra. Tuy nhiên, vẫn tồn tại một số trường hợp mô hình dự đoán sai, chủ yếu rơi vào hai dạng:

Ảnh viêm phổi nhưng bị dự đoán nhầm là bình thường (False Negative),

Ảnh bình thường nhưng bị dự đoán nhầm là viêm phổi (False Positive).

Trong số đó, *False Negative* là dạng lỗi nghiêm trọng hơn trong bối cảnh y tế, do có thể dẫn đến việc bỏ sót bệnh nhân mắc bệnh. Kết quả cho thấy mô hình vẫn còn hạn chế trong việc phân biệt các trường hợp viêm phổi có biểu hiện mờ nhạt hoặc không điển hình trên ảnh X-ray.

3. Ảnh hưởng của tiền xử lý và kích thước ảnh

Một trong những yếu tố ảnh hưởng trực tiếp đến kết quả là *kích thước ảnh đầu vào*. Việc giảm kích thước ảnh xuống 32×32 giúp giảm đáng kể chi phí tính toán và đảm bảo khả năng huấn luyện mô hình từ đầu trong thời gian hợp lý. Tuy nhiên, điều này cũng làm mất đi nhiều chi tiết quan trọng của ảnh X-ray, dẫn đến hiện tượng ảnh hiển thị mờ và có thể làm giảm độ chính xác của mô hình trong một số trường hợp khó.

Mặc dù vậy, kết quả thực nghiệm cho thấy mô hình vẫn có khả năng học được *các mẫu cường độ tổng quát và phân bố sáng-tối* của ảnh phổi, đủ để phân biệt hai lớp trong nhiều trường hợp. Điều này cho thấy hướng tiếp cận sử dụng ảnh độ phân giải thấp là một *đánh đổi hợp lý* trong bối cảnh cài đặt mô hình từ đầu.

4. So sánh với các baseline

So với các baseline được trình bày ở mục 5.2, mô hình học sâu 5 lớp cho kết quả tốt hơn so với các mô hình nông hơn (ít lớp ẩn), đặc biệt về các chỉ số Recall và F1-score. Điều này cho thấy *độ sâu mô hình* đóng vai trò quan trọng trong việc học các biểu diễn phi tuyến từ dữ liệu ảnh.

Bên cạnh đó, các thí nghiệm không chuẩn hóa dữ liệu đầu vào cho thấy quá trình huấn luyện kém ổn định hơn và hội tụ chậm hơn, khẳng định *tầm quan trọng của bước tiền xử lý* trong các mô hình học sâu.

5. Hạn chế của mô hình

Mặc dù đạt được kết quả khả quan, mô hình đề xuất vẫn tồn tại một số hạn chế:

Không khai thác trực tiếp cấu trúc không gian của ảnh như các mạng CNN,

Nhạy cảm với chất lượng tiền xử lý và kích thước ảnh đầu vào,

Hiệu suất chưa thể so sánh với các mô hình học sâu hiện đại sử dụng thư viện chuyên dụng.

Những hạn chế này là điều khó tránh khỏi trong bối cảnh mô hình được cài đặt hoàn toàn từ đầu và với mục tiêu học tập của học phần.

6. Nhận xét chung

Tổng hợp các kết quả thực nghiệm cho thấy mô hình học sâu 5 lớp được xây dựng từ đầu *đáp ứng tốt mục tiêu của đề tài*, cả về mặt học thuật lẫn thực hành. Mặc dù kiến trúc đơn giản, mô hình vẫn thể hiện được khả năng phân loại ảnh X-ray viêm phổi ở mức chấp nhận được, đồng thời giúp làm rõ bản chất của các thuật toán học sâu cơ bản.

Kết quả này khẳng định rằng việc xây dựng mô hình học sâu từ đầu là một hướng tiếp cận hiệu quả để *nắm vững nền tảng học sâu*, tạo tiền đề cho việc phát triển các mô hình phức tạp hơn và các ứng dụng thời gian thực trong giai đoạn tiếp theo của học phần.

VI. Kết luận và hướng phát triển

6.1. Kết luận

Trong báo cáo này, một *mô hình học sâu nhiều lớp (MLP 5 lớp)* được xây dựng hoàn toàn từ đầu đã được đề xuất và áp dụng cho bài toán phân loại ảnh X-ray lồng ngực nhằm phát hiện bệnh viêm phổi. Toàn bộ quá trình xây dựng mô hình, từ tiền xử lý dữ liệu, thiết kế kiến trúc mạng, lan truyền xuôi, lan truyền ngược cho đến huấn luyện và đánh giá, đều được cài đặt thủ công bằng Python mà không sử dụng các thư viện học sâu chuyên dụng.

Kết quả thực nghiệm cho thấy mô hình có khả năng học được các đặc trưng tổng quát từ dữ liệu ảnh X-ray và đạt được hiệu quả phân loại ở mức chấp nhận được, mặc dù kiến trúc mô hình đơn giản và dữ liệu đầu vào có độ phân giải thấp. Điều này chứng minh rằng ngay cả với các mô hình học sâu cơ bản, việc cài đặt từ đầu vẫn có thể giải quyết các bài toán thực tế, đồng thời giúp người học hiểu rõ hơn bản chất của các thuật toán học sâu.

Quan trọng hơn, quá trình triển khai mô hình từ đầu đã giúp củng cố các kiến thức nền tảng của học sâu, bao gồm vai trò của hàm kích hoạt, hàm mất mát, thuật toán lan truyền ngược và phương pháp tối ưu tham số. Đây là những yếu tố cốt lõi để tiếp cận và phát triển các mô hình học sâu phức tạp hơn trong các giai đoạn tiếp theo.

6.2. Hướng phát triển

Dựa trên các kết quả đạt được và những hạn chế đã phân tích, đề tài có thể được mở rộng và phát triển theo nhiều hướng trong tương lai, đặc biệt phù hợp với yêu cầu của **đề án cuối kỳ** của học phần:

Nâng cao kiến trúc mô hình: Mở rộng mô hình sang các kiến trúc học sâu chuyên biệt cho ảnh như mạng nơ-ron tích chập (CNN), nhằm khai thác tốt hơn cấu trúc không gian của ảnh X-ray.

Cải thiện tiền xử lý và biểu diễn dữ liệu: Áp dụng các kỹ thuật nâng cao như tăng cường dữ liệu (data augmentation) hoặc sử dụng ảnh có độ phân giải cao hơn khi có đủ tài nguyên tính toán.

Tối ưu hóa quá trình huấn luyện: Thử nghiệm các chiến lược tối ưu nâng cao như adaptive learning rate hoặc regularization để cải thiện khả năng tổng quát hóa của mô hình.

Triển khai ứng dụng thời gian thực: Xây dựng hệ thống dự đoán viêm phổi từ ảnh X-ray theo thời gian thực, ví dụ thông qua giao diện người dùng hoặc ứng dụng web, nhằm minh họa tính ứng dụng của mô hình trong thực tế.

Đánh giá trên tập dữ liệu mở rộng: Kiểm tra mô hình trên các bộ dữ liệu ảnh y tế khác nhằm đánh giá khả năng tổng quát và độ ổn định của phương pháp.

Các hướng phát triển trên không chỉ giúp cải thiện hiệu suất mô hình mà còn mở ra cơ hội áp dụng học sâu vào các bài toán thực tế phức tạp hơn, phù hợp với mục tiêu đào tạo và nghiên cứu của học phần Fundamental of Deep Learning.

VII. Tài liệu tham khảo

[1] Paul Mooney, *Chest X-Ray Images (Pneumonia)*, Kaggle Dataset.

Truy cập tại: <https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia>

[2] Ian Goodfellow, Yoshua Bengio, Aaron Courville, *Deep Learning*, MIT Press, 2016.

[3] Christopher M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.

[4] Simon Haykin, *Neural Networks and Learning Machines*, 3rd Edition, Pearson Education, 2009.

[5] Aurélien Géron, *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow*, O'Reilly Media, 2019.

[6] Karen Simonyan and Andrew Zisserman, “Very Deep Convolutional Networks for Large-Scale Image Recognition,” *International Conference on Learning Representations (ICLR)*, 2015.

[7] Kaiming He et al., “Deep Residual Learning for Image Recognition,” *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[8] TS.Lê Minh Huy, *Bài giảng môn Fundamental of Deep Learning*, Trường Đại học Phenikaa, 2024.

VIII. Lời cảm ơn

Em xin gửi lời cảm ơn chân thành đến thầy TS. Lê Minh Huy, giảng viên môn *Fundamental of Deep Learning*, Trường Đại học Phenikaa, đã tận tình giảng dạy, hướng dẫn và cung cấp những kiến thức nền tảng quan trọng giúp em hoàn thành bài báo cáo này.

Em cũng xin cảm ơn nhà trường và khoa đã tạo điều kiện thuận lợi về cơ sở vật chất, học liệu và môi trường học tập để em có thể nghiên cứu, thực hành và tiếp cận các kiến thức về học sâu một cách hiệu quả.

Cuối cùng, em xin cảm ơn bạn bè và những người đã hỗ trợ, trao đổi và đóng góp ý kiến trong quá trình thực hiện báo cáo, giúp em hoàn thiện nội dung và kết quả của đề tài.